

**ĐẠI HỌC TRÀ VINH
TRƯỜNG KỸ THUẬT VÀ CÔNG NGHỆ**



**ĐỒ ÁN TỐT NGHIỆP
Phân đoạn khối u não dựa trên cải tiến U-Net**

Giảng viên hướng dẫn : **ThS. NGUYỄN MỘNG HIỀN**

Sinh viên thực hiện: **HUỲNH PHẠM NHẬT AN**

Mã số sinh viên: **110122027**

Lớp : **DA22TTA**

Khoá : **2022**

Vĩnh Long, tháng 6 năm 2026

**ĐẠI HỌC TRÀ VINH
TRƯỜNG KỸ THUẬT VÀ CÔNG NGHỆ**



**ĐỒ ÁN TỐT NGHIỆP
Phân đoạn khối u não dựa trên cải tiến U-Net**

Giảng viên hướng dẫn : ThS. NGUYỄN MỘNG HIỀN

Sinh viên thực hiện: HUỲNH PHẠM NHẬT AN

Mã số sinh viên: 110122027

Lớp : DA22TTA

Khoá : 2022

Vĩnh Long, tháng 6 năm 2026

MỤC LỤC

CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI	1
1.1 Lý do chọn đề tài	1
1.2 Mục tiêu nghiên cứu	1
1.3 Đối tượng và phạm vi nghiên cứu	2
1.4 Phương pháp nghiên cứu	2
1.5 Mô tả bài toán	3
1.6 Bố cục đồ án	4
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT	5
2.1. Phân đoạn ảnh y tế và phân loại bài toán	5
2.2. Mạng nơ-ron tích chập	7
2.2.1. Khối tích chập	7
2.2.2. Lớp gộp mẫu	7
2.2.3. Chuẩn hóa theo lô (Batch Normalization)	8
2.2.4. Hàm kích hoạt phi tuyến	8
2.3.Kiến trúc U-Net [1]	9
2.3.1. Bộ mã hóa	10
2.3.2. Tích chập chuyển vị (Transposed Convolution)	11
2.3.3. Bộ giải mã	13
2.3.4. Kết nối tắt (Skip Connections)	14
2.4. Bộ biến đổi thị giác và cơ chế tự chú ý (Self-Attention)	15
2.4.1. Khối nhúng phân mảnh và mã hóa vị trí	16
2.4.2. Cơ chế tự chú ý	17
2.4.3. Cơ chế chú ý đa đầu	18
2.4.4. Bộ mã hóa Transformer (Transformer Encoder)	19
2.4.5. So sánh bộ biến đổi thị giác với mạng nơ-ron tích chập	20
2.5. Cơ chế công chú ý	22
2.6. Thước đo đánh giá và Hàm mất mát trong phân đoạn ảnh y khoa	23
2.6.1. Ma trận nhầm lẫn	23
2.6.2. Hàm mất mát Focal Tversky (Focal Tversky Loss)	23

2.6.3. Hệ số Dice và chỉ số IoU	24
CHƯƠNG 3: ĐỀ XUẤT GIẢI PHÁP, THIẾT KẾ HỆ MÔ HÌNH	25
3.1. Tập dữ liệu nghiên cứu	25
3.2. Nhược điểm của mô hình U-Net chuẩn	27
3.3. Phương pháp cải tiến	28
3.3.1. Các cải tiến và đóng góp	28
3.3.2. Kiến trúc sau cải tiến	29
3.3.3. Nhúng mảnh (Patch Embedding) và Mã hóa vị trí (Positional Encoding)	30
3.4. Van lọc nhiễu chủ động	33
3.5. Vận hành chi tiết luồng giải mã	34
3.6. Hàm mất mát đa mục tiêu	36
3.6.1. Hàm mất mát Entropy chéo nhị phân (Binary Cross-Entropy Loss)	36
3.6.2. Hàm mất mát Dice (Dice Loss)	37
3.6.3. Hàm DiceEntropy chéo nhị phân hàm mất mát	37
CHƯƠNG 4: THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ	38
4.1. Môi trường và thiết lập thực nghiệm	38
4.1.1. Môi trường phần cứng và phần mềm	38
4.1.2. Thiết lập siêu tham số huấn luyện	38
4.2. Các độ đo đánh giá	39
4.3. Kết quả đánh giá định lượng	39
4.3.1. Phân tích độ ổn định	40
4.3.2. Đánh giá tốc độ suy luận	41
4.3.3. Biểu đồ trực quan hóa quá trình huấn luyện	41
4.4. Phân tích trực quan định tính	46
CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	51
5.1. Kết luận và các đóng góp cốt lõi của đề tài	51
5.2. Các mặt hạn chế còn tồn tại	51
5.3. Hướng phát triển mở rộng trong tương lai	52
DANH MỤC TÀI LIỆU THAM KHẢO	53

LỜI MỞ ĐẦU

Trong những năm gần đây, sự phát triển bùng nổ của Trí tuệ nhân tạo, đặc biệt là lĩnh vực Học sâu, đã mang lại những ứng dụng to lớn trong đời sống con người. Nổi bật trong số đó là các ứng dụng hỗ trợ y tế thông minh, nơi AI đang dần trở thành cánh tay đắc lực giúp các bác sĩ chẩn đoán bệnh lý chính xác và nhanh chóng hơn.

Nhận thức được ý nghĩa thực tiễn và tính cấp thiết của công nghệ này, đặc biệt trong việc chẩn đoán các căn bệnh hiểm nghèo như u não, em đã quyết định lựa chọn đề tài: "Phân đoạn khối u não dựa trên cải tiến U-Net" làm Đồ án tốt nghiệp của mình. Đồ án không chỉ là cơ hội để em áp dụng những kiến thức lý thuyết đã học trên giảng đường vào việc giải quyết một bài toán thực tế, mà còn là bước đệm quan trọng giúp em tiếp cận với những công nghệ hiện nay như Bộ biến đổi thị giác (VisionTransformer).

LỜI CẢM ƠN

Để hoàn thành Đồ án tốt nghiệp này, em đã nhận được sự quan tâm, chỉ bảo và giúp đỡ nhiệt tình từ rất nhiều cá nhân và tập thể. Nhờ có những nguồn động viên to lớn đó, em mới có thể vượt qua những khó khăn trong quá trình nghiên cứu và lập trình để đạt được kết quả như ngày hôm nay.

Trước tiên, em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến toàn thể quý Thầy/Cô giáo Khoa Công nghệ Thông tin - Đại học Trà Vinh. Những kiến thức chuyên môn vững chắc và kỹ năng tư duy logic mà Thầy/Cô truyền đạt trong suốt những năm tháng giảng đường chính là hành trang quý giá nhất để em bước vào môi trường nghiên cứu và thực tiễn.

Đặc biệt, em xin gửi lời tri ân sâu sắc đến Giảng viên hướng dẫn thầy Nguyễn Mộng Hiền. Thầy là người đã trực tiếp giao đề tài, tận tình hướng dẫn, định hướng lộ trình nghiên cứu và cung cấp cho em những lời khuyên chuyên môn cực kỳ quý báu. Mặc dù bận rộn với công việc giảng dạy, thầy vẫn luôn dành thời gian theo dõi tiến độ và giải đáp những vướng mắc của em. Sự tâm huyết của thầy chính là động lực to lớn nhất giúp em hoàn thành tốt đồ án này.

Mặc dù đã nỗ lực hết mình, song do những giới hạn về mặt thời gian, tài nguyên máy tính cũng như trình độ chuyên môn của một sinh viên, đồ án chắc chắn không thể tránh khỏi những thiếu sót nhất định. Em rất mong nhận được sự lượng thứ, cũng như những ý kiến đóng góp, chỉ bảo từ Hội đồng bảo vệ và quý Thầy/Cô để đồ án được hoàn thiện hơn. Những lời góp ý của Thầy/Cô sẽ là bài học vô giá giúp em vững bước trên con đường sự nghiệp sau này.

Em xin chân thành cảm ơn!

[illegible]

Giảng viên hướng dẫn
(ký và ghi rõ họ tên)

Họ và tên sinh viên: MSSV:
 Ngành:..... Khóa:
 Tên đề tài:.....

Họ và tên Giáo viên hướng dẫn:.....
 Chức danh: Học vi:

1. Nội dung đề tài:

This image shows a blank sheet of white paper with horizontal ruling lines. The lines are evenly spaced and extend across the width of the page. There are no margins, text, or other markings on the paper.

.....

.....

.....

.....

.....

.....

.....

.....

.....

SVTH: Huỳnh Phạm Nhật An

.....

.....

.....

.....

.....

5. Giá trị thực trên đề tài:

.....

.....

.....

.....

.....

.....

7. Đề nghị sửa chữa bổ sung:

.....

.....

.....

.....

.....

.....

8. Đánh giá:

.....

.....

.....

.....

Vĩnh Long, ngày tháng năm 20...

Giảng viên hướng dẫn

(Ký & ghi rõ họ tên)

[illegible]

Giảng viên chấm
(ký và ghi rõ họ tên)

BẢN NHẬN XÉT ĐỒ ÁN, KHÓA LUẬN TỐT NGHIỆP
(Của cán bộ chấm đồ án, khóa luận)

Họ và tên người nhận xét:
Chức danh: Học vị:
Chuyên ngành:
Cơ quan công tác:
Tên sinh viên:
Tên đề tài đồ án, khóa luận tốt nghiệp:
.....
.....

I. Ý KIẾN NHẬN XÉT

1. Nội dung:
-
.....
.....
.....
.....
.....
.....
.....
.....
.....
2. Điểm mới các kết quả của đồ án, khóa luận:
-
.....
.....
3. Ứng dụng thực tế:
-
.....
.....
.....
.....
.....

(Các câu hỏi của giáo viên phản biện)

III. KẾT LUẬN

Người nhận xét
(Ký & ghi rõ họ tên)

DANH MỤC HÌNH

Hình 2.1 Kỹ thuật khoanh vùng và phân vùng u não trên ảnh chụp cộng hưởng từ.....	5
Hình 2.2 Các phương pháp phân vùng ảnh ứng dụng trong chẩn đoán u não.....	6
Hình 2.3 Kiến trúc mạng U-Net[1].....	10
Hình 2.4 Kiến trúc U-Net với bộ mã hóa[1].....	11
Hình 2.5 Minh họa bước nhân tích chập và xử lý dịch chuyển stride [4].....	12
Hình 2.6 Minh họa bước xử lý chồng chéo[4].....	13
Hình 2.7 Minh họa bước áp dụng đệm biên[4].....	13
Hình 2.8 Kiến trúc U-Net với bộ giải mã[4].....	14
Hình 2.9 Quy trình xử lý ảnh đầu vào của bộ biến đổi thị giác trong mô hình cải tiến.....	15
Hình 2.10 Sơ đồ minh họa quá trình nhúng mảnh mã hóa vị trí.....	17
Hình 2.11 Cấu trúc của một khối mã hóa trong bộ biến đổi thị giác.....	19
Hình 2.12 Quy trình xử lý ảnh chụp cộng hưởng từ bằng bộ biến đổi thị giá....	22
Hình 3.1 Ảnh Chụp cộng hưởng từ đầu vào.....	25
Hình 3.2 Ảnh Nhãn.....	26
Hình 3.3 Kiến trúc mô hình sau cải tiến.....	29
Hình 3.4 Quá trình nhúng mảnh và mã hóa vị trí trong mô hình cải tiến.....	31
Hình 3.5 Kiến trúc một khối mã hóa Transformer trong mô hình cải tiến.....	32
Hình 3.6 Quá trình tái cấu trúc không gian đầu ra bộ biến đổi thị giác.....	32
Hình 3.7 Cơ chế công chú ý kết hợp kết nối tắt và nâng cấp độ phân giải trong bộ giải mã.....	34
Hình 3.8 Cơ chế công chú ý trong khối giải mã thứ hai.....	35
Hình 3.9 Cơ chế công chú ý trong khối giải mã thứ ba.....	35
Hình 3.10 Lớp đầu ra tạo mặt nạ phân đoạn.....	36
Hình 4.1 Biểu đồ tiến trình huấn luyện của mô hình cải tiến.....	42
Hình 4.2 Tiến trình huấn luyện U-Net hàm mất mát qua các vòng huấn luyện..	43
Hình 4.3 Tiến trình huấn luyện mô hình cải tiến hàm mất mát qua các vòng huấn luyện.....	44

Hình 4.4 Biểu đồ chỉ số Dice của U-Net.....	44
Hình 4.5 Biểu đồ chỉ số Dice của mô hình cải tiến.....	45
Hình 4.6 Trực quan hóa mặt nạ phân đoạn khối u giữa mô hình U-Net và mô hình cải tiến so với nhãn thực tế 1.....	46
Hình 4.7 Trực quan hóa mặt nạ phân đoạn khối u giữa mô hình U-Net và mô hình cải tiến so với nhãn thực tế 2.....	47
Hình 4.8 Trực quan hóa mặt nạ phân đoạn khối u giữa mô hình U-Net và Mô hình cải tiến so với nhãn thực tế 3.....	49

DANH MỤC BẢNG

Bảng 2.1 So sánh bộ biến đổi thị giác với mạng nơ-ron tích chập.....	21
Bảng 4.1 So sánh hiệu năng giữa U-Net và mô hình cải tiến.....	39

CHƯƠNG 1: TỔNG QUAN ĐỀ TÀI

1.1 Lý do chọn đề tài

Khối u não là một trong những bệnh lý nguy hiểm và có tỷ lệ tử vong cao trên toàn thế giới. Để chẩn đoán và lên phác đồ điều trị, phương pháp chụp cộng hưởng từ được sử dụng phổ biến nhờ khả năng cung cấp hình ảnh chi tiết về cấu trúc mô mềm của não bộ. Tuy nhiên, quá trình khoanh vùng phân đoạn khối u trên các lát cắt chụp cộng hưởng từ hiện nay chủ yếu được thực hiện thủ công bởi các bác sĩ chẩn đoán hình ảnh. Công việc này không chỉ tốn nhiều thời gian, công sức mà còn mang tính chủ quan, dễ dẫn đến sai sót do sự mệt mỏi hoặc mức độ phức tạp của hình dạng khối u.

Trong những năm gần đây, trí tuệ nhân tạo, đặc biệt là học sâu, đã mang lại những bước tiến đột phá trong lĩnh vực xử lý ảnh y tế. Kiến trúc mạng U-Net đã trở thành kiến trúc nền tảng phổ biến cho bài toán phân đoạn ảnh y tế nhờ khả năng trích xuất đặc trưng cục bộ hiệu quả thông qua các lớp tích chập. Tuy nhiên, mạng nơ-ron tích chập còn hạn chế trong việc nắm bắt các mối liên hệ ngữ cảnh từ xa, khiến mô hình đôi khi nhận diện sai ranh giới của những khối u có hình dạng phức tạp.

Sự ra đời của mô hình bộ biến đổi thị giác (Vision Transformer - ViT) với cơ chế tự chú ý đã góp phần cải thiện khả năng mô hình hóa ngữ cảnh toàn cục. Xuất phát từ thực tiễn trên, đề tài "Phân đoạn khối u não dựa trên cải tiến U-Net" được lựa chọn nghiên cứu. Việc kết hợp ưu điểm trích xuất chi tiết cục bộ của mạng nơ-ron tích chập và khả năng hiểu ngữ cảnh toàn cục của bộ biến đổi được kỳ vọng góp phần xây dựng công cụ tự động có độ chính xác cao, hỗ trợ quá trình chẩn đoán cho các bác sĩ.

1.2 Mục tiêu nghiên cứu

Đề tài được thực hiện với các mục tiêu chính sau:

- Về lý thuyết: Nghiên cứu tổng quan về bài toán phân đoạn ảnh y tế; tìm hiểu kiến trúc U-Net và mô hình bộ biến đổi thị giác trong phân đoạn ảnh y tế.
- Về thực hành: Xây dựng mô hình U-Net cơ sở và đề xuất mô hình cải tiến để giải quyết triệt để vấn đề.

- Về đánh giá: Huấn luyện, thử nghiệm và so sánh hiệu năng của hai mô hình trên bộ dữ liệu ảnh cộng hưởng từ (Low-Grade Glioma - LGG) dựa trên các thang đo y tế chuẩn xác như chỉ số Dice và chỉ số IoU.

1.3 Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu:

- Các kỹ thuật tiền xử lý và tăng cường ảnh y tế.
- Các mô hình học sâu dùng cho phân đoạn ảnh y tế, bao gồm U-Net, Vision Transformer.
- Các hàm mất mát phù hợp với bài toán mất cân bằng dữ liệu trong phân đoạn ảnh y tế.

Phạm vi nghiên cứu:

- Đề tài chỉ tập trung vào bài toán phân đoạn nhị phân để tách vùng khối u và vùng nền không chứa khối u trên ảnh chụp cộng hưởng từ 2D.
- Dữ liệu thử nghiệm được giới hạn ở bộ dữ liệu mở ảnh cộng hưởng từ u thần kinh đệm bậc thấp.

1.4 Phương pháp nghiên cứu

Để đạt được các mục tiêu đã đề ra, đề án áp dụng các phương pháp nghiên cứu sau:

Phương pháp thu thập và tiền xử lý dữ liệu: Sử dụng bộ dữ liệu được công bố trên Kaggle, áp dụng các kỹ thuật tăng cường dữ liệu như xoay, lật và biến dạng đàn hồi để làm phong phú dữ liệu. Phân chia tập dữ liệu theo cấp độ bệnh nhân để đảm bảo tính khách quan.

Phương pháp thực nghiệm: Xây dựng và triển khai mô hình bằng thư viện PyTorch. Huấn luyện mô hình trên môi trường điện toán đám mây Kaggle với GPU được Kaggle cung cấp.

Phương pháp đánh giá và phân tích: Sử dụng các chỉ số đánh giá định lượng để so sánh định lượng, đồng thời so sánh định tính bằng cách chồng mặt nạ dự đoán lên ảnh gốc để đối chiếu với nhãn phân đoạn chuẩn.

1.5 Mô tả bài toán

Bài toán phân đoạn khối u não được phát biểu như sau: Cho một ảnh chụp cộng hưởng từ dạng 2D của não bộ bệnh nhân, hệ thống cần tự động xác định và phân loại từng điểm ảnh thuộc vùng khối u hoặc vùng nền, từ đó tạo ra một mặt nạ nhị phân nhằm khoanh vùng chính xác ranh giới của khối u.

Dữ liệu đầu vào: Ảnh chụp cộng hưởng từ não bộ 2D dạng FLAIR (Fluid Attenuated Inversion Recovery) có kích thước 256×256 pixel, gồm 3 kênh màu. Mỗi ảnh đầu vào tương ứng với một lát cắt ngang trong chuỗi quét MRI của bệnh nhân.

Dữ liệu đầu ra mong muốn: Một ảnh nhị phân có cùng kích thước 256×256 điểm ảnh, trong đó mỗi điểm ảnh chỉ mang một trong hai giá trị: 1 hoặc 0.

Phân loại bài toán: Đây là bài toán phân đoạn ngữ nghĩa nhị phân ở mức điểm ảnh. Khác với bài toán phân loại ảnh, chỉ gán một nhãn duy nhất cho toàn bộ ảnh, hoặc bài toán phát hiện đối tượng, chỉ xác định vị trí đối tượng thông qua hộp giới hạn, bài toán phân đoạn ngữ nghĩa yêu cầu mô hình đưa ra quyết định phân loại đối với từng điểm ảnh trong ảnh. Do đó, mô hình phải đạt được độ chính xác không gian cao nhằm xác định chính xác vị trí và ranh giới của vùng khối u.

Thách thức đặc thù của bài toán:

Mất cân bằng dữ liệu nghiêm trọng: Trong một lát cắt ảnh chụp cộng hưởng từ, vùng khối u chỉ chiếm khoảng 1–2% tổng diện tích ảnh, trong khi phần còn lại là vùng nền. Sự chênh lệch lớn về tỷ lệ giữa hai lớp khiến mô hình dễ có xu hướng dự đoán toàn bộ ảnh là vùng nền nhằm đạt được độ chính xác cao một cách giả tạo.

Ranh giới mờ nhạt: Biên giữa mô khối u và mô não lành thường không rõ ràng, đặc biệt đối với các khối u thần kinh đệm bậc thấp, do mật độ tín hiệu của khối u gần tương đồng với mô não bình thường. Điều này làm gia tăng độ khó trong quá trình xác định chính xác ranh giới phân đoạn.

Hình dạng và kích thước đa dạng: Khối u não không có hình dạng cố định, có thể xuất hiện tại bất kỳ vị trí nào trong não với kích thước dao động từ vài điểm ảnh đến chiếm phần lớn bán cầu não. Sự đa dạng về hình dạng, kích thước và vị trí xuất hiện đặt ra yêu cầu đối với mô hình phải có khả năng học và khái quát hóa tốt để phân đoạn chính xác trong nhiều trường hợp khác nhau.

1.6 Bố cục đồ án

Báo cáo đồ án được trình bày với cấu trúc gồm 5 chương:

Chương 1: Phần mở đầu. Trình bày lý do chọn đề tài, mục tiêu, đối tượng, phạm vi và phương pháp nghiên cứu.

Chương 2: Cơ sở lý thuyết. Cung cấp kiến thức nền tảng về xử lý ảnh y tế, mạng nơ-ron tích chập, cấu trúc U-Net và cơ chế của bộ biến đổi thị giác.

Chương 3: Phương pháp và mô hình đề xuất. Trình bày chi tiết luồng xử lý dữ liệu, kiến trúc mạng U-Net cơ sở và kiến trúc mô hình đề xuất được điều chỉnh phù hợp với bài toán nghiên cứu.

Chương 4: Thực nghiệm và đánh giá kết quả. Trình bày môi trường cài đặt, quy trình huấn luyện, biểu đồ hội tụ và phân tích so sánh kết quả giữa các mô hình.

Chương 5: Kết luận và hướng phát triển. Tổng kết các đóng góp của đề tài, nêu ra những hạn chế và đề xuất hướng nghiên cứu mở rộng trong tương lai.


CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Phân đoạn ảnh y tế và phân loại bài toán

Phân đoạn ảnh (Image Segmentation) là một kỹ thuật cơ bản trong lĩnh vực thị giác máy tính, có nhiệm vụ phân chia một bức ảnh thành các phần tử nhỏ hơn gọi là các vùng hoặc đoạn. Mục đích chính của quá trình này là chuyển đổi dữ liệu ảnh ban đầu của ảnh gốc thành một dạng dữ liệu có ý nghĩa ngữ nghĩa rõ ràng hơn, nhằm hỗ trợ việc phân tích và xử lý tiếp theo.

Phân đoạn ảnh thực hiện một phép gán nhãn ở cấp độ điểm ảnh, trong đó mỗi điểm ảnh trong ảnh được phân loại và gán vào một nhóm cụ thể. Những điểm ảnh cùng nhóm thường đại diện cho các đối tượng vật lý hoặc các khu vực có đặc tính tương tự nhau. Quá trình này cho phép máy tính hiểu được cấu trúc không gian của ảnh một cách chi tiết và chính xác.

Phân đoạn ảnh và phát hiện đối tượng (Object Detection) đều có chung mục tiêu là xác định các vùng chứa đối tượng và gán nhãn cho chúng, tuy nhiên, phân đoạn ảnh yêu cầu độ chính xác cao hơn. Khác với phát hiện đối tượng, nơi đối tượng được định vị thông qua các hộp giới hạn, phân đoạn ảnh yêu cầu nhãn dự đoán phải chính xác đến từng điểm ảnh trong ảnh. Điều này giúp chúng ta hiểu rõ hơn về nội dung bức ảnh, không chỉ dừng lại ở việc xác định vị trí các đối tượng mà còn mô tả được hình dạng của chúng, cũng như gán từng điểm ảnh vào đúng đối tượng tương ứng.




Hình 2.1 Kỹ thuật khoanh vùng và phân vùng u não trên ảnh chụp cộng hưởng từ

Phân đoạn ảnh được chia làm 3 loại chính [1]:

Phân đoạn ngữ nghĩa (Semantic Segmentation): Gán nhãn cho từng điểm ảnh trong ảnh và nhóm các điểm ảnh có cùng ngữ nghĩa vào một lớp cụ thể. Quá trình này phân đoạn các vùng ảnh theo từng lớp khác nhau mà không phân biệt giữa các đối tượng riêng lẻ thuộc cùng một lớp.

Phân đoạn thực thể (Instance Segmentation): Phân đoạn các vùng ảnh chi tiết đến từng đối tượng trong mỗi lớp.

Phân đoạn toàn cảnh (Panoptic segmentation): Kết hợp giữa phân đoạn ngữ nghĩa và phân đoạn thực thể, mỗi đối tượng được phân đoạn với ranh giới rõ ràng, đồng thời danh tính và ý nghĩa của từng đối tượng được dự đoán.



Hình 2.2 Các phương pháp phân vùng ảnh ứng dụng trong chẩn đoán u não.

Đồ án này tập trung giải quyết bài toán phân đoạn ảnh nhị phân trên ảnh chụp cộng hưởng từ não. Đầu vào của mô hình là ảnh chụp cộng hưởng từ có kích thước $H \times W \times C$. Đầu ra của mô hình là một mặt nạ phân đoạn có kích thước $H \times W \times 1$, trong đó mỗi điểm ảnh mang giá trị nhị phân:

- 0: vùng não bình thường hoặc hộp sọ
- 1: vùng chứa khối u não.

2.2. Mạng nơ-ron tích chập

2.2.1. Khối tích chập

Tích chập (Convolution) là thành phần cốt lõi của mạng nơ-ron tích chập. Thay vì kết nối toàn bộ các nơ-ron với nhau như mạng truyền thẳng truyền thống, mạng nơ-ron tích chập sử dụng các ma trận nhỏ gọi là bộ lọc để quét qua ảnh đầu vào theo cả chiều ngang và chiều dọc.

Mỗi bộ lọc có khả năng học và trích xuất một đặc trưng cụ thể từ ảnh chụp cộng hưởng từ. Một bộ lọc có thể học cách nhận diện biên mô não, cấu trúc mô hoặc vùng bất thường về cường độ tín hiệu, trong khi bộ lọc khác có thể phát hiện các vùng bất thường về cường độ xám liên quan đến khối u não.

Khi tensor đầu vào có kích thước (H_{in}, W_{in}) khi đi qua phép tích chập với:

- Bộ lọc kích thước $K \times K$
- Bước trượt S
- Phân đệm biên P

kích thước đầu ra được tính theo công thức:

$$H_{out} = \left\lfloor \frac{H_{in} - K + 2P}{S} \right\rfloor + 1 \quad (2.1)$$

$$W_{out} = \left\lfloor \frac{W_{in} - K + 2P}{S} \right\rfloor + 1 \quad (2.2)$$

2.2.2. Lớp gộp mẫu

Lớp gộp mẫu (Pooling Layer) được sử dụng để giảm kích thước không gian của bản đồ đặc trưng, từ đó giúp giảm số lượng tham số và chi phí tính toán của mạng nơ-ron tích chập. Đồng thời, quá trình này còn giúp mô hình tăng tính bất biến đối với vị trí, nghĩa là khối u não vẫn có thể được nhận diện ngay cả khi vị trí của nó thay đổi nhẹ trên ảnh cộng hưởng từ.

Một trong những phương pháp phổ biến nhất là gộp cực đại (Max Pooling), trong đó mạng sẽ giữ lại giá trị lớn nhất trong mỗi vùng gộp. Điều này giúp mô hình tập trung vào các đặc trưng nổi bật và quan trọng nhất.

2.2.3. Chuẩn hóa theo lô (Batch Normalization)

Chuẩn hóa theo lô là một kỹ thuật được sử dụng rộng rãi trong các mạng nơ-ron tích chập nhằm cải thiện độ ổn định và tăng tốc quá trình huấn luyện. Kỹ thuật này thực hiện chuẩn hóa các đặc trưng đầu ra của mỗi lớp dựa trên giá trị trung bình và phương sai của từng lô dữ liệu, giúp đưa dữ liệu về phân phối có giá trị trung bình xấp xỉ 0 và phương sai xấp xỉ 1.

Trong kiến trúc U-Net và mô hình cải tiến, lớp chuẩn hóa theo lô được đặt sau mỗi lớp tích chập và trước hàm kích hoạt ReLU, tạo thành cấu trúc: Tích chập - Chuẩn hóa theo lô - ReLU. Cách bố trí này giúp quá trình huấn luyện ổn định hơn, cho phép sử dụng tốc độ học lớn hơn, đồng thời góp phần cải thiện khả năng hội tụ và nâng cao hiệu quả huấn luyện của mô hình.

2.2.4. Hàm kích hoạt phi tuyến

Trong bài toán phân đoạn ảnh cộng hưởng từ não, hình dạng của khối u thường rất phức tạp, không cố định và có thể lan rộng theo nhiều hướng khác nhau. Vì vậy, các phép biến đổi tuyến tính đơn thuần không đủ khả năng mô tả các đặc trưng này. Để tăng khả năng học các mối quan hệ phi tuyến trong dữ liệu, mạng nơ-ron tích chập sử dụng các hàm kích hoạt.

Hàm ReLU (Rectified Linear Unit) là một trong những hàm kích hoạt phổ biến nhất trong mạng nơ-ron tích chập, được định nghĩa như sau:

$$f(x) = \max(0, x) \quad (2.3)$$

Hàm đơn vị tuyến tính được sửa chữa sẽ đưa mọi giá trị âm về 0, trong khi các giá trị dương được giữ nguyên. Nhờ đó, mô hình có thể:

- Loại bỏ các tín hiệu yếu hoặc nhiễu không cần thiết
- Tăng tốc quá trình huấn luyện
- Hạn chế hiện tượng mất gradient

Trong bài toán ảnh chụp cộng hưởng từ não, đơn vị tuyến tính được sửa chữa giúp mạng tập trung nhiều hơn vào các vùng đặc trưng quan trọng như mô bất thường hoặc ranh giới khối u.

Hàm Sigmoid

Hàm Sigmoid là một hàm kích hoạt phi tuyến thường được sử dụng ở lớp đầu ra của các bài toán phân loại nhị phân và phân đoạn ảnh nhị phân. Hàm Sigmoid được định nghĩa như sau:

$$\text{Sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2.4)$$

Hàm này ánh xạ mọi giá trị thực vào khoảng (0,1), cho phép đầu ra được diễn giải dưới dạng xác suất.

Trong bài toán phân đoạn khối u não trên ảnh cộng hưởng từ, giá trị đầu ra của hàm Sigmoid biểu thị xác suất một điểm ảnh thuộc về vùng khối u.

- Giá trị gần 0: điểm ảnh được dự đoán thuộc mô bình thường
- Giá trị gần 1: điểm ảnh được dự đoán thuộc vùng khối u


2.3.Kiến trúc U-Net [1]

Được công bố bởi Ronneberger, U-Net được phát triển cho phân đoạn ảnh y sinh học với khả năng hoạt động hiệu quả trên dữ liệu ảnh cộng hưởng từ hoặc ảnh chụp cắt lớp vi tính hạn chế.

U-Net là một mạng nơ-ron tích chập được thiết kế ban đầu cho phân đoạn ảnh y sinh. Kiến trúc của U-Net bao gồm hai phần chính là bộ mã hóa (encoder) và bộ giải mã (decoder) đối xứng nhau với hình dạng giống chữ U.

Bộ mã hóa: có nhiệm vụ trích xuất đặc trưng từ ảnh đầu vào thông qua các lớp tích chập và lớp gộp mẫu. Trong quá trình này, kích thước không gian của ảnh giảm dần trong khi số lượng đặc trưng được tăng lên.

Bộ giải mã: có nhiệm vụ khôi phục kích thước ảnh và tạo ra bản đồ phân đoạn cuối cùng thông qua các lớp lấy mẫu lên và tích chập.



Hình 2.3 Kiến trúc mạng U-Net.[1]

Hình trên mô tả kiến trúc mạng U-Net, trong đó:

1. Mỗi hình chữ nhật màu xanh biểu thị một bản đồ đặc trưng đa kênh.
2. Các mũi tên màu xanh dương biểu thị phép tích chập 3×3 kết hợp với hàm kích hoạt đơn vị tuyến tính được sửa chữa.
3. Số lượng kênh đặc trưng được ghi phía trên mỗi hình chữ nhật.
4. Kích thước không gian được ghi ở góc dưới bên trái của mỗi hình.
5. Các hình chữ nhật màu trắng đại diện cho các bản đồ đặc trưng được sao chép từ nhánh bộ mã hóa sang bộ giải mã thông qua kết nối tắt (Skip Connection).
6. Các mũi tên biểu thị các phép toán khác nhau:
 - Mũi tên đỏ: Gộp cực đại 2×2
 - Mũi tên xanh lá: Tích chập chuyển vị 2×2
 - Mũi tên xám: Sao chép và cắt
 - Mũi tên xanh ngọc: Tích chập 1×1


2.3.1. Bộ mã hóa

Bộ mã hóa nằm ở nửa luồng đi xuống bên trái của chữ U. Thành phần này hoạt động như một khối trích xuất đặc trưng truyền thống có vai trò tương tự phần trích xuất đặc trưng trong các mạng tích chập

Tại mỗi mức của bộ mã hóa, dữ liệu lần lượt đi qua các lớp tích chập kích thước 3×3 kết hợp với hàm kích hoạt đơn vị tuyến tính được sửa chữa và sau đó được giảm kích thước không gian bằng lớp gộp cực đại 2×2 . Quá trình này giúp mô hình trích xuất các đặc trưng có mức biểu diễn ngày càng cao và có ý nghĩa.

Càng đi sâu xuống đáy kiến trúc chữ U, kích thước không gian của bản đồ đặc trưng giảm dần, nhưng số lượng kênh đặc trưng lại tăng dần từ 64 lên 128, 256, 512 và 1024 kênh. Nhờ đó, mô hình có thể học được các đặc trưng ở nhiều mức độ khác nhau, từ các cạnh và kết cấu đơn giản đến các cấu trúc phức tạp.

Chức năng chính của bộ mã hóa là xác định nội dung ngữ nghĩa của ảnh. Bằng cách nén thông tin, nó giảm bớt thông tin không gian chi tiết không cần thiết và trích xuất thông tin ngữ nghĩa quan trọng để nhận diện các cấu trúc như mô não, vùng bất thường và ranh giới khối u.



Hình 2.4 Kiến trúc U-net với bộ mã hóa [1]

2.3.2. Tích chập chuyển vị (Transposed Convolution)

Khi mạng đi đến phần đáy của kiến trúc U-Net, kích thước không gian của bản đồ đặc trưng đã giảm đáng kể. Để tạo ra mặt nạ phân đoạn có kích thước tương ứng với ảnh đầu vào, bộ giải mã cần thực hiện quá trình khôi phục

độ phân giải không gian của các bản đồ đặc trưng. U-Net sử dụng tích chập chuyển vị thay vì các phương pháp nội suy thông thường.


Các phương pháp nội suy cơ bản thường tăng kích thước ảnh bằng cách nhân bản hoặc tính toán giá trị mới từ các điểm ảnh lân cận để điền vào khoảng trống. Tuy nhiên, các phương pháp này không học tham số từ dữ liệu, nên có thể làm mất một số chi tiết không gian quan trọng [1].

Ngược lại, tích chập chuyển vị cho phép mạng nơ-ron học các trọng số trong quá trình huấn luyện. Phép toán này có thể được xem như một cơ chế tăng kích thước không gian của bản đồ đặc trưng.

Bằng cách thiết lập kích thước bộ lọc và bước trượt phù hợp, tích chập chuyển vị giúp mô hình học cách tăng kích thước bản đồ đặc trưng, đồng thời hỗ trợ khôi phục cấu trúc không gian của vùng khối u và các thông tin chi tiết [1].


Quy trình thực hiện Tích chập chuyển vị:

Nhân với bộ lọc và xử lý bước trượt: Mỗi phần tử trong bản đồ đặc trưng đầu vào được nhân với toàn bộ ma trận bộ lọc. Thay vì nén lại như tích chập thông thường, kết quả sinh ra một ma trận con và được đặt tương ứng trên bản đồ đặc trưng đầu ra. Với bước trượt là S, sau khi xử lý xong điểm ảnh thứ nhất, vị trí đặt ma trận con tiếp theo trên ảnh đầu ra sẽ được dịch chuyển đi S điểm ảnh. Bước trượt S càng lớn, bức ảnh đầu ra sẽ càng được tăng kích thước ra [1].




Hình 2.5 Minh họa bước nhân tích chập và xử lý dịch chuyển stride [4]

Xử lý chồng chéo : Do quá trình dịch chuyển bằng stride, các ma trận con trên ảnh đầu ra thường sẽ có những khu vực bị đè lên nhau. Tại các điểm giao nhau này, giá trị của các điểm ảnh sẽ được cộng dồn lại với nhau để khôi phục và củng cố cường độ sáng của viền khối u não [1].



Hình 2.6 Minh họa bước xử lý chồng chéo[4]

Áp dụng đệm biên (padding): Tương tự như tích chập tiêu chuẩn, đệm biên trong tích chập chuyển vị được sử dụng để điều chỉnh kích thước không gian của bản đồ đặc trưng đầu ra. Tuy nhiên, nó có cơ chế điều chỉnh khác bằng cách lược bỏ các viền biên của ma trận đầu ra để đưa bản đồ đặc trưng về kích thước mục tiêu, đảm bảo bản đồ đặc trưng phù hợp với cấu trúc của khối u [1].



Hình 2.7 Minh họa bước áp dụng đệm biên.[4]


2.3.3. Bộ giải mã

Nằm ở nửa luồng đi lên bên phải của chữ U, bộ giải mã có nhiệm vụ khôi phục thông tin đặc trưng đã được nén.

Tại mỗi tầng giải mã, mô hình sẽ sử dụng tích chập chuyển vị để tăng gấp đôi độ phân giải kích thước không gian và giảm đi một nửa số lượng kênh đặc trưng.

Tiếp theo, nó áp dụng các khối Tích chập liên tiếp để chất lọc và tinh chỉnh đặc trưng lại thông tin hình ảnh.

Chức năng cốt lõi của bộ giải mã là xác định vị trí của các điểm ảnh thuộc vùng khối u trên ảnh đầu vào. Nó tái tạo lại hình dạng và ranh giới của vùng khối u để khớp với tỷ lệ ảnh gốc.



Hình 2.8 Kiến trúc U-net với bộ giải mã.[4]

2.3.4. Kết nối tắt (Skip Connections)

U-Net trong lĩnh vực xử lý ảnh y tế. Việc giảm kích thước không gian thông qua quá trình trích mẫu xuống liên tục làm suy giảm thông tin vị trí không gian của đối tượng. Nếu chỉ dựa vào tích chập chuyển vị đi thực hiện quá trình giải mã, nhánh bộ giải mã sẽ chỉ tạo ra một kết quả phân đoạn có độ chính xác thấp, bản đồ phân đoạn thiếu chi tiết hình khối u mà không thể xác định chính xác các đường biên phức tạp, phân định ranh giới đối tượng [1].

Để khắc phục hạn chế này, U-Net tạo ra kết nối tắt kết nối trực tiếp các bản đồ đặc trưng từ từng tầng bên trái bộ mã hóa sang thẳng nhánh phải bộ giải mã có cùng một cấp độ phân giải. Các bản đồ đặc trưng từ luồng bộ mã hóa chứa thông tin vị trí không gian chi tiết của khối u thần kinh đệm do chưa bị suy giảm đáng kể về thông tin không gian. Chúng được nối gộp thẳng vào từng tầng tương ứng của nhánh giải mã.


Nhờ có kết nối tốt, bộ giải mã được bổ sung thông tin vị trí không gian chi tiết để có thể phục hồi và tái tạo chính xác các đặc trưng ranh giới của đường

viền u não, gần tương đồng với nhãn phân đoạn được xây dựng bởi chuyên gia y tế [1].

2.4. Bộ biến đổi thị giác và cơ chế tự chú ý (Self-Attention)

Bộ biến đổi thị giác là một mô hình học sâu đột phá, được nhóm nghiên cứu Google Research giới thiệu tại hội nghị ICLR 2021 trong công trình "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale". Mô hình này ứng dụng kiến trúc bộ biến đổi vốn đã đạt được nhiều thành công, cho thấy hiệu quả vượt trội, được ứng dụng rộng rãi trong lĩnh vực Xử lý ngôn ngữ tự nhiên để giải quyết các bài toán thị giác máy tính [2].

Về bản chất, bộ biến đổi thị giác không sử dụng các phép toán tích chập truyền thống. Thay vào đó, nó chia bức ảnh đầu vào thành nhiều mảnh nhỏ có kích thước cố định, mỗi mảnh ảnh được chuyển đổi thành một vector đặc trưng và được xem như một đơn vị đầu vào tương tự như cách bộ biến đổi xử lý các từ trong một câu văn. Điều này cho phép bộ biến đổi thị giác tận dụng cơ chế tự chú ý hiệu quả để học mối quan hệ phụ thuộc giữa các vùng khác nhau của bức ảnh, bất kể khoảng cách không gian giữa chúng [2].



Hình 2.9 Quy trình xử lý ảnh đầu vào của bộ biến đổi thị giác trong mô hình cải tiến

2.4.1. Khối nhúng phân mảnh và mã hóa vị trí

Bộ biến đổi ban đầu được thiết kế để xử lý chuỗi từ (tokens) trong một đoạn văn. Để áp dụng cho ảnh chụp cộng hưởng từ hai chiều, bức ảnh cần được chuyển đổi thành một chuỗi một chiều thông qua hai bước: phân mảnh và nhúng đặt trung [2].

Bước 1 Phân ảnh thành các mảnh

Ảnh đầu vào kích thước $H \times W$ được chia thành các mảnh vuông không chồng chéo có kích thước $P \times P$. Tổng số mảnh thu được tính theo công thức:

$$N = \frac{H \times W}{P^2} \quad (2.5)$$

Với ảnh chụp cộng hưởng từ não kích thước 256×256 và kích thước mảnh $P=16$, số lượng mảnh ảnh (patch) thu được là:

$$\frac{256 \times 256}{16 \times 16} = 256 \quad (2.6)$$

Mỗi mảnh ảnh lúc này được xem như một chuỗi từ trong chuỗi đầu vào của bộ biến đổi.

Bước 2 Nhúng tuyến tính

Mỗi mảnh ảnh có kích thước $P \times P \times C$ với C là số kênh ảnh sẽ được trải phẳng thành vector một chiều, sau đó ánh xạ sang không gian đặc trưng có kích thước D thông qua phép biến đổi tuyến tính.

$$\mathbf{z}_i = \mathbf{x}_i^{patch} \cdot \mathbf{W}_E + \mathbf{b}_E \quad (2.7)$$

Trong đó:

$\mathbf{x}_i^{patch}$ vector của mảnh ảnh thứ i

$\mathbf{W}_E$ ma trận trọng số học được

$\mathbf{b}_E$ vector độ lệch bias


$\mathbf{z}_i$ vector biểu diễn đặt trung (embedding) đầu ra

Bước 3 Mã hóa vị trí

Bộ biến đổi xử lý toàn bộ chuỗi song song nên không tự nhận biết được vị trí của từng phần tử trong chuỗi đầu vào. Do đó, nếu chỉ sử dụng biểu diễn đặc trưng thông thường, mô hình sẽ không phân biệt được vị trí không gian của các mảnh ảnh trên ảnh cộng hưởng từ.

Để khắc phục vấn đề này, một vector mã hóa vị trí sẽ được cộng vào biểu diễn đặc trưng của từng mảnh ảnh.

Nhờ mã hóa vị trí (Positional Encoding), bộ biến đổi có thể học được mối quan hệ không gian giữa các vùng khác nhau của ảnh chụp cộng hưởng từ, từ đó cải thiện khả năng nhận diện cấu trúc và vị trí của khối u não.



Hình 2.10 Sơ đồ minh họa quá trình nhúng mảnh (Patch Embedding) mã hóa vị trí

2.4.2. Cơ chế tự chú ý

Tự chú ý là thành phần cốt lõi của bộ biến đổi thị giác, cho phép mô hình đánh giá mức độ liên quan giữa một mảnh ảnh với tất cả mảnh ảnh trong ảnh [2].

Từ vector biểu diễn đặc trưng đầu vào $\mathbf{z}'_i$, mô hình tạo ra ba vector đặc trưng thông qua các ma trận trọng số học được:

Truy vấn (Q): biểu diễn thông tin truy vấn của mảnh ảnh hiện tại

Key (K): biểu diễn đặc trưng nhận dạng của từng mảnh ảnh

Value (V): chứa thông tin nội dung của mảnh ảnh

Các vector này được tính như sau:

$$\mathbf{Q} = \mathbf{z}' \cdot \mathbf{W}_Q$$

$$\mathbf{K} = \mathbf{z}' \cdot \mathbf{W}_K$$

$$\mathbf{V} = \mathbf{z}' \cdot \mathbf{W}_V$$

Trong đó:

$\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V$ là các ma trận trọng số được học trong quá trình huấn luyện.

Cơ chế tự chú ý cho phép mô hình học được mối quan hệ giữa các vùng khác nhau trong toàn bộ ảnh chụp cộng hưởng từ, kể cả khi chúng nằm cách xa nhau về mặt không gian.

Một mảnh ảnh chứa vùng mô não ở bán cầu trái có thể học được mối liên hệ với một mảnh khác chứa vùng bất thường ở bán cầu phải nếu hai vùng này có đặc trưng liên quan đến khối u. Điều này giúp bộ biến đổi thị giác khai thác được thông tin ngữ cảnh toàn cục, trong khi các mạng nơ-ron tích chập truyền thống với bộ lọc kích thước nhỏ như 3×3 thường chỉ tập trung vào vùng cục bộ.

2.4.3. Cơ chế chú ý đa đầu

Một cơ chế tự chú ý đơn lẻ có thể bị hạn chế trong việc biểu diễn đồng thời nhiều loại mối quan hệ giữa các mảnh ảnh. Tuy nhiên, trong ảnh chụp cộng hưởng từ não tồn tại nhiều đặc trưng và mối liên hệ khác nhau cần được khai thác đồng thời, chẳng hạn như tính đối xứng giữa hai bán cầu não, ranh giới giữa mô lành và khối u, hoặc mối liên hệ giữa vùng phù nề và vùng hoại tử [2].

Để giải quyết vấn đề này, bộ biến đổi thị giác sử dụng cơ chế chú ý đa đầu (Multi-Head Attention), trong đó nhiều đầu tự chú ý được thực hiện song song. Mỗi đầu chú ý có khả năng tập trung vào một kiểu quan hệ hoặc một đặc trưng khác nhau của dữ liệu đầu vào.

Công thức của chú ý đa đầu được biểu diễn như sau:

$$MultiHead(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = Concat(\mathbf{head}_1, \mathbf{head}_2, \dots, \mathbf{head}_h) \cdot \mathbf{W}_o \quad (2.8)$$

Trong đó, mỗi đầu chú ý được tính theo công thức:


$$\mathbf{head}_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (2.9)$$

Các đầu chú ý sau khi được tính toán sẽ được nối lại và đưa qua phép biến đổi tuyến tính sử dụng ma trận $\mathbf{W}_O$ để tạo ra biểu diễn đầu ra cuối cùng.

Với:

- h : số lượng đầu chú ý
- $\mathbf{W}_Q^i, \mathbf{W}_K^i, \mathbf{W}_V^i$ ma trận trọng số của đầu chú ý thứ i
- $\mathbf{W}_O$ ma trận trọng số đầu ra

2.4.4. Bộ mã hóa Transformer (Transformer Encoder)



Hình 2.11 Cấu trúc của một khối mã hóa Transformer trong bộ biến đổi thị giác

Một khối bộ mã hóa Transformer được cấu thành từ hai thành phần chính là chú ý đa đầu và mạng truyền thẳng nhiều lớp. Trước mỗi thành phần, dữ liệu được đưa qua lớp chuẩn hóa và sau mỗi thành phần đều sử dụng kết nối tắt để duy trì luồng thông tin và hỗ trợ quá trình huấn luyện sâu. Cấu trúc này được lặp lại nhiều lần nhằm học các biểu diễn đặc trưng ngày càng giàu ngữ nghĩa từ chuỗi mảnh ảnh đầu vào [2].

Số lượng khối mã hóa được lựa chọn là 4 nhằm phù hợp với đặc điểm của tập dữ liệu ảnh cộng hưởng từ não LGG MRI. Do quy mô dữ liệu tương đối hạn chế, việc sử dụng quá nhiều khối có thể làm tăng số lượng tham số của mô hình, dẫn đến nguy cơ quá khớp và làm tăng chi phí tính toán. Vì vậy, cấu hình gồm 4 khối mã hóa được lựa chọn nhằm cân bằng giữa khả năng học đặc trưng toàn cục và khả năng tổng quát hóa của mô hình.

Chuẩn hóa lớp (Layer Normalization)

Chuẩn hóa lớp được sử dụng để chuẩn hóa phân phối của các đặc trưng đầu vào trong các khối của mạng nơ-ron, đặc biệt là trong cơ chế tự chú ý đa đầu và mạng truyền thẳng của kiến trúc bộ biến đổi. Kỹ thuật này giúp ổn định quá trình huấn luyện và cải thiện tốc độ hội tụ của mô hình.

Khác với chuẩn hóa theo lô (Batch Normalization), chuẩn hóa lớp thực hiện việc chuẩn hóa trên từng mẫu dữ liệu độc lập thay vì toàn bộ lô dữ liệu, do đó không phụ thuộc vào kích thước lô dữ liệu và phù hợp với kiến trúc bộ biến đổi [2].

Cơ chế tự chú ý đa đầu (Multi-Head Self-Attention)

Sau bước chuẩn hóa lớp, chuỗi các vector đặc trưng được đưa vào cơ chế tự chú ý đa đầu để tính toán mức độ liên quan giữa các mảnh ảnh khác nhau.

Nhờ đó, mô hình có thể khai thác thông tin từ toàn bộ ảnh thay vì chỉ tập trung vào các vùng lân cận, giúp học được ngữ cảnh toàn cục và các mối quan hệ không gian giữa các cấu trúc trong ảnh cộng hưởng từ.[2]

Kết nối dư (Residual Connection)

Trong kiến trúc Transformer, cơ chế kết nối dư được sử dụng bằng cách cộng trực tiếp đầu vào của một tầng với đầu ra của tầng đó trước khi chuyển sang bước xử lý tiếp theo. Cơ chế này đóng vai trò quan trọng trong việc cải thiện khả năng huấn luyện của mô hình, cụ thể:

- Duy trì luồng thông tin
- Hạn chế hiện tượng mất gradient
- Hỗ trợ huấn luyện các mô hình sâu hiệu quả hơn

2.4.5. So sánh bộ biến đổi thị giác với mạng nơ-ron tích chập

Tiêu chí so sánh	Bộ biến đổi thị giác	Mạng nơ-ron tích chập truyền thống
Kiến trúc	Xử lý ảnh dưới dạng chuỗi các mảnh .	Sử dụng lớp tích chập trượt bộ lọc theo tầng.

Tiêu chí so sánh	Bộ biến đổi thị giác	Mạng nơ-ron tích chập truyền thống
Khai thác đặc trưng	Học quan hệ toàn cục ngay từ lớp đầu tiên.	Bắt đầu từ đặc trưng cục bộ, dần mở rộng qua các tầng sâu.
Tầm nhìn	Mỗi mảnh nhìn thấy toàn bộ $N-1$ mảnh còn lại.	Mỗi điểm ảnh chỉ nhìn thấy $3 \times 3 = 9$ điểm ảnh lân cận trong một bước tích chập.
Yêu cầu dữ liệu	Cần tập dữ liệu lớn hoặc quy trình pre-train để phát huy tối đa sức mạnh.	Hoạt động tốt và ổn định với tập dữ liệu vừa và nhỏ.
Ưu thế y khoa	Phát hiện mối liên hệ xa giữa khối u và vùng phù nề cách xa nhau.	Giỏi phát hiện cạnh, hình dáng, và kết cấu cục bộ của mô não/tế bào.

Bảng 2.1 So sánh bộ biến đổi thị giác với mạng nơ-ron tích chập

Quá trình xử lý của bộ biến đổi thị giác trong bài toán phân đoạn ảnh y tế được thực hiện qua bốn giai đoạn chính:

Tiền xử lý: Ảnh chụp cộng hưởng từ đầu vào không được đưa trực tiếp vào bộ biến đổi mà được chia thành các mảnh ảnh có kích thước bằng nhau. Mỗi mảnh ảnh sau đó được làm phẳng và chuyển thành một vector một chiều, tạo thành một chuỗi các vector đặc trưng để làm đầu vào cho mô hình.


Nhúng đặc trưng và nhúng vị trí: Chuỗi vector đầu vào được ánh xạ sang không gian đặc trưng có cùng số chiều thông qua một lớp nhúng tuyến tính.

Đồng thời, thông tin vị trí của từng mảnh ảnh được bổ sung bằng vector nhúng vị trí, giúp mô hình bảo toàn thông tin không gian giữa các mảnh ảnh.

Mã hóa thông tin ngữ cảnh toàn cục: Chuỗi đặc trưng sau khi được nhúng lần lượt đi qua các khối bộ mã hóa Transformer. Trong mỗi khối, cơ chế tự chú ý đa đầu cho phép mô hình học mối quan hệ giữa các mảnh ảnh trên toàn bộ ảnh

đầu vào, từ đó khai thác hiệu quả thông tin ngữ cảnh toàn cục và biểu diễn đặc trưng có tính toàn diện hơn.

Khôi phục bản đồ đặc trưng: Đầu ra của bộ biến đổi được tái cấu trúc từ chuỗi vector thành bản đồ đặc trưng hai chiều.



Hình 2.12 Quy trình xử lý ảnh chụp cộng hưởng từ bằng bộ biến đổi thị giá.

2.5. Cơ chế công chú ý

Trong kiến trúc U-Net gốc, các kết nối tắt truyền toàn bộ bản đồ đặc trưng từ bộ mã hóa sang bộ giải mã, bao gồm cả những vùng thông tin không liên quan như mô lành hoặc hộp sọ. Điều này có thể làm giảm khả năng tập trung của mô hình vào vùng khối u cần phân đoạn.

Công chú ý được đề xuất nhằm giải quyết vấn đề này bằng cách xác định và tăng cường các đặc trưng có liên quan trước khi truyền sang bộ giải mã.

Tín hiệu x từ bộ mã hóa chứa thông tin đặc trưng không gian của ảnh chụp cộng hưởng từ

Tín hiệu g từ bộ giải mã mang thông tin ngữ nghĩa ở mức sâu hơn về vùng mà mô hình đang quan tâm

Hai tín hiệu này được kết hợp để tạo ra một bản đồ chú ý với các hệ số $\alpha \in [0,1]$. Giá trị α thể hiện mức độ quan trọng của từng vị trí không gian trên bản đồ đặt trung:

- α gần 0: vùng ít quan trọng
- α gần 1: vùng quan trọng cần được giữ lại

Nhờ cơ chế này, các vùng không liên quan như các cấu trúc nền hoặc vùng không thuộc khối u sẽ bị suy giảm ảnh hưởng, trong khi các vùng chứa đặc trưng của khối u được tăng cường. Điều này giúp mô hình tập trung tốt hơn vào khu vực cần phân đoạn và cải thiện độ chính xác của kết quả phân đoạn ảnh Chụp cộng hưởng từ não.

2.6. Thước đo đánh giá và Hàm mất mát trong phân đoạn ảnh y khoa

2.6.1. Ma trận nhầm lẫn

Trong bài toán phân đoạn ảnh y tế, mỗi điểm ảnh trong ảnh chụp cộng hưởng từ được phân loại vào một trong bốn trường hợp sau:

- Dương tính thật (True Positive) : Điểm ảnh thuộc vùng khối u và được mô hình dự đoán đúng là khối u.
- Âm tính thật (True Negative): Điểm ảnh thuộc mô não bình thường và được mô hình dự đoán đúng là không thuộc khối u.
- Dương tính giả (False Positive): Điểm ảnh thuộc mô não bình thường nhưng bị mô hình dự đoán nhầm là khối u.
- Âm tính giả (False Negative): Điểm ảnh thuộc vùng khối u nhưng mô hình không phát hiện được.

Trong lĩnh vực y tế, lỗi âm tính giả đặc biệt nguy hiểm vì có thể dẫn đến bỏ sót tổn thương và ảnh hưởng đến quá trình điều trị của bệnh nhân.

2.6.2. Hàm mất mát Focal Tversky (Focal Tversky Loss)

Trong ảnh chụp cộng hưởng từ não, vùng khối u thường chiếm tỷ lệ rất nhỏ so với toàn bộ ảnh, dẫn đến hiện tượng mất cân bằng lớp. Nếu sử dụng các

hàm mất mát thông thường như Cross-Entropy, mô hình có xu hướng ưu tiên dự đoán lớp nền do số lượng điểm ảnh nền chiếm đa số.

Hàm mất mát Focal Tversky được đề xuất nhằm cải thiện khả năng phân đoạn của mô hình trong các bài toán phân đoạn có mất cân bằng dữ liệu cao. Hàm mất mát này mở rộng từ chỉ số Tversky bằng cách sử dụng các hệ số α và β để điều chỉnh mức độ ảnh hưởng của các lỗi dương tính giả và âm tính giả trong quá trình tối ưu hóa mô hình.

2.6.3. Hệ số Dice và chỉ số IoU

IoU (Intersection over Union)

Chỉ số IoU là độ đo đánh giá mức độ chồng chéo giữa vùng dự đoán và vùng nhãn thực tế. Chỉ số này được tính theo công thức:

$$IoU = \frac{TP}{TP+FP+FN} \quad (2.10)$$

Giá trị IoU càng cao cho thấy kết quả phân đoạn càng chính xác.

Giá trị IoU nằm trong khoảng từ 0 đến 1. Giá trị càng lớn cho thấy mức độ chồng chéo giữa vùng dự đoán và vùng thực tế càng cao, đồng nghĩa với kết quả phân đoạn càng chính xác.

Hệ số Dice

Hệ số Dice là một độ đo được sử dụng rộng rãi trong phân đoạn ảnh y tế nhằm đánh giá mức độ tương đồng giữa vùng dự đoán và vùng nhãn thực tế. Chỉ số này được tính theo công thức:

$$Dice = \frac{2TP}{2TP+FP+FN} \quad (2.11)$$

Giá trị Dice cũng nằm trong khoảng từ 0 đến 1, trong đó giá trị càng gần 1 cho thấy kết quả phân đoạn càng chính xác.

So với IoU, hệ số Dice nhấn mạnh hơn vào phần giao nhau giữa vùng dự đoán và vùng thực tế thông qua hệ số 2 ở tử số. Do đó, Dice thường cho giá trị cao hơn IoU trên cùng một tập dữ liệu và được sử dụng phổ biến trong các nghiên cứu phân đoạn ảnh cộng hưởng từ não.

CHƯƠNG 3: ĐỀ XUẤT GIẢI PHÁP, THIẾT KẾ HỆ MÔ HÌNH

3.1. Tập dữ liệu nghiên cứu

Để huấn luyện và đánh giá mô hình, nghiên cứu sử dụng bộ dữ liệu LGG MRI Segmentation Dataset được công bố trên nền tảng Kaggle. Đây là một bộ dữ liệu mã nguồn mở phổ biến trong lĩnh vực phân đoạn ảnh cộng hưởng từ não, được sử dụng rộng rãi trong các nghiên cứu về phát hiện và phân đoạn u thần kinh đệm cấp thấp

Tổng quan về tập dữ liệu

Bộ dữ liệu được thu thập từ khoảng 110 bệnh nhân với các mã định danh riêng biệt như:

- TCGA_CS_4941
- TCGA_CS_4942


Mỗi bệnh nhân bao gồm nhiều lát cắt chụp cộng hưởng từ não được chụp theo các mặt phẳng khác nhau nhằm cung cấp thông tin không gian về cấu trúc não và vùng tổn thương.

Cấu trúc dữ liệu hình ảnh

Tập dữ liệu bao gồm 7.858 file ảnh định dạng .tif, gồm:

- 3.929 ảnh Chụp cộng hưởng từ gốc
- 3.929 ảnh nhãn

Ảnh Chụp cộng hưởng từ đầu vào



Hình 3.1 Ảnh Chụp cộng hưởng từ đầu vào

Các ảnh chụp cộng hưởng từ được tổng hợp từ nhiều chuỗi xung chụp cộng hưởng từ như:

- FLAIR
- T1-weighted (T1w)
- T1-weighted contrast-enhanced (T1gd)
- T2-weighted (T2w)

Ảnh Nhãn

Mỗi ảnh Chụp cộng hưởng từ đi kèm một ảnh nhãn được các chuyên gia y tế đánh dấu thủ công:



Hình 3.2 Ảnh Nhãn

- Điểm ảnh giá trị 1 biểu thị vùng khối u
- Điểm ảnh giá trị 0 biểu thị mô não bình thường hoặc nền ảnh

Các ảnh nhãn này đóng vai trò là dữ liệu mục tiêu trong quá trình huấn luyện mô hình phân đoạn.

Dữ liệu lâm sàng

Ngoài dữ liệu hình ảnh, bộ dữ liệu còn cung cấp tệp data.csv chứa các thông tin lâm sàng và nhân khẩu học của bệnh nhân như tuổi, giới tính, loại mô học, vị trí khối u và cấp độ ác tính. Các thông tin này có thể được sử dụng trong các nghiên cứu phân tích lâm sàng hoặc xây dựng các mô hình dự đoán đa phương thức. Tuy nhiên, trong phạm vi nghiên cứu này, mô hình chỉ sử dụng dữ liệu hình ảnh và ảnh nhãn để huấn luyện và đánh giá.

Tiền xử lý dữ liệu

Trước khi đưa vào huấn luyện, toàn bộ dữ liệu được tiền xử lý nhằm đảm bảo tính đồng nhất:

- Chuẩn hóa kích thước ảnh về 256×256
- Chuẩn hóa giá trị điểm ảnh về khoảng $[0,1]$.

- Đồng bộ định dạng đầu vào của mô hình

Việc chuẩn hóa dữ liệu giúp cải thiện độ ổn định và tốc độ hội tụ trong quá trình huấn luyện mạng nơ-ron sâu.

Thách thức mất cân bằng lớp

Một trong những thách thức lớn nhất của bài toán phân đoạn khối u não là hiện tượng mất cân bằng lớp. Trong nhiều lát cắt ảnh chụp cộng hưởng từ, diện tích vùng khối u chỉ chiếm một tỷ lệ rất nhỏ, đôi khi dưới 1% tổng số điểm ảnh của ảnh, trong khi phần lớn còn lại là nền.

Điều này khiến các mô hình học sâu truyền thống dễ thiên về dự đoán lớp nền nhằm đạt độ chính xác tổng thể cao, dẫn đến:

- Bỏ sót vùng khối u nhỏ
- Tăng số lượng âm tính giả
- Giảm hiệu quả phân đoạn thực tế

Để giải quyết vấn đề này, đồ án sử dụng các hàm mất mát chuyên biệt như hàm mất mát Focal Tversky kết hợp với trọng số phạt nhằm tăng khả năng phát hiện các vùng khối u nhỏ trên ảnh chụp cộng hưởng từ não.

3.2. Nhược điểm của mô hình U-Net chuẩn

Qua quá trình thực nghiệm huấn luyện trên tập dữ liệu Kaggle, hiệu suất của U-Net truyền thống có xu hướng hội tụ và chững lại ở mức hệ số Dice được tính trên tập dữ liệu xấp xỉ 0.8352. Mặc dù đây là một mức điểm khá, nhưng qua thử nghiệm cho thấy giới hạn này xuất phát từ hai nhược điểm cố hữu trong kiến trúc của mạng, khiến nó gặp khó khăn ở những ca bệnh khó:

Hạn chế về trường nhìn cảm nhận và thiếu hụt ngữ cảnh toàn cục:

U-Net phụ thuộc hoàn toàn vào các bộ lọc tích chập cục bộ. Dù trải qua nhiều lớp hạ lấy mẫu để tiến tới nút thắt cổ chai, trường nhìn cảm nhận của mạng vẫn bị giới hạn đáng kể. Mạng thiếu đi khả năng nắm bắt mối tương quan không gian ở khoảng cách xa trên toàn bộ cấu trúc não bộ. Hậu quả là U-Net có thể xảy ra hiện tượng phân đoạn thừa, nhận diện nhầm các cấu trúc mô lành hoặc vân não có cường độ tín hiệu tương đồng với khối u do thiếu thông tin định

vị ngữ nghĩa tổng thể. Bất cứ vùng mô lành hay vân não nào có cường độ sáng lên một chút đều bị U-Net dự đoán nhầm là khối u.

Truyền dẫn nhiều qua cơ chế kết nối tắt: Trong U-Net gốc, dữ liệu đặc trưng từ luồng bộ mã hóa được truyền trực tiếp và nối ghép vào luồng bộ giải mã cùng cấp. Mặc dù cơ chế này giúp khôi phục chi tiết không gian, nó đồng thời mang theo một lượng lớn các đặc trưng dư thừa và nhiễu nền bao gồm hộp sọ, màng não và các vùng không chứa bệnh lý. Việc không chắt lọc tín hiệu khiến mạng giải mã bị quá tải thông tin nhiễu, làm giảm độ tập trung vào vùng khối u mục tiêu và gây suy giảm độ sắc nét của biên giới phân đoạn.

3.3. Phương pháp cải tiến

Nhằm cải thiện khả năng phân đoạn khối u não trên ảnh chụp cộng hưởng từ, Nghiên cứu đề xuất một mô hình cải tiến dưới dạng kiến trúc lai, kết hợp giữa:

- Mạng nơ-ron tích chập trong U-Net để trích xuất đặc trưng cục bộ.
- Bộ biến đổi thị giác để khai thác thông tin ngữ cảnh toàn cục.
- Cơ chế công chú ý để chọn lọc đặc trưng quan trọng.

Mô hình thực hiện quá trình biến đổi từ ảnh chụp cộng hưởng từ đầu vào có kích thước $256 \times 256 \times 3$ thành mặt nạ phân đoạn đầu ra kích thước $256 \times 256 \times 1$.

Khác với U-Net truyền thống, mô hình cải tiến thay thế khối nút thắt cổ chai mạng nơ-ron tích chập bằng các khối bộ biến đổi nhằm tăng khả năng khai thác mối quan hệ toàn cục giữa các vùng khác nhau trên ảnh chụp cộng hưởng từ.

3.3.1. Các cải tiến và đóng góp

Nhằm giải quyết triệt để các nhược điểm của kiến trúc U-Net và tối ưu hóa cho phù hợp với tập dữ liệu.

1. Khắc phục hạn chế cục bộ bằng bộ biến đổi thị giác

Điểm khác biệt quan trọng nhất so với U-Net truyền thống là việc loại bỏ hoàn toàn khối mạng nơ-ron tích chập tại vùng đáy mạng và thay thế bằng kiến trúc bộ biến đổi thị giác. Trong khi U-Net chỉ khai thác đặc trưng cục bộ dẫn đến hiện tượng nhầm lẫn mô lành thành khối u thì bộ biến đổi thị giác cung cấp khả năng nhìn toàn cục, cho phép mô hình liên kết thông tin từ toàn bộ ảnh não, từ đó giảm thiểu hiện tượng phân đoạn thừa.


2. Khắc phục nhiễu truyền dẫn bằng cổng chú ý (Attention Gate)

Thay vì sao chép toàn bộ đặc trưng từ nhánh mã hóa sang nhánh giải mã như U-Net chuẩn, em đã tích hợp cơ chế cổng chú ý vào các kết nối tắt. Cổng này hoạt động như một bộ lọc thông minh, loại bỏ các đặc trưng nhiễu hộp sọ, màng não, vân não từ nhánh bộ mã hóa, giúp nhánh bộ giải mã tập trung vào việc tái tạo biên giới khối u một cách chính xác.

3. Khắc phục mất cân bằng lớp bằng DiceBCELoss

Hàm mất mát kết hợp DiceBCELoss được tùy biến với trọng số phạt $\text{pos_weight} = 15.0$. Thiết kế này buộc mô hình chú trọng đến các khối u có kích thước nhỏ, khắc phục xu hướng dự đoán toàn bộ ảnh thành nền đen một vấn đề phổ biến trong các mạng CNN y tế cơ bản.

3.3.2. Kiến trúc sau cải tiến



Hình 3.3 Kiến trúc mô hình sau cải tiến

Mô hình thực hiện thực hiện quá trình phân đoạn từ ảnh chụp cộng hưởng từ đầu vào có kích thước $256 \times 256 \times 3$ thành mặt nạ phân đoạn đầu ra kích thước $256 \times 256 \times 1$.

Khác với U-Net truyền thống, mô hình cải tiến thay thế tầng đặc trưng sâu nhất của U-Net bằng khối bộ biến đổi thị giác nhằm tăng khả năng khai thác các mối quan hệ phụ thuộc dài hạn và thông tin ngữ cảnh toàn cục trên ảnh chụp cộng hưởng từ.

3.3.3. Nhúng mảnh (Patch Embedding) và Mã hóa vị trí (Positional Encoding)

Trong kiến trúc đề xuất, sau khi ảnh chụp cộng hưởng từ đi qua toàn bộ nhánh Mạng nơ-ron tích chập bộ mã hóa, đầu ra tại tầng sâu nhất thu được bản đồ đặc trưng kích thước $32 \times 32 \times 512$. Tuy nhiên, bộ biến đổi không được thiết kế để xử lý trực tiếp dữ liệu từ bản đồ đặc trưng dạng hai chiều, vì vậy cần có bước chuyển đổi gồm hai giai đoạn:


Nhúng mảnh có nhiệm vụ chuyển đổi bản đồ đặc trưng thành dạng chuỗi biểu diễn đặc trưng mà bộ biến đổi có thể xử lý. Bản đồ đặc trưng 32×32 được chia thành $32 \times 32 = 1024$ mảnh ảnh, mỗi mảnh ảnh kích thước 1×1 . Tiếp theo, mỗi mảnh ảnh được ánh xạ tuyến tính từ không gian đặc trưng 512 chiều sang không gian nhúng 768 chiều. Kết quả thu được chuỗi mã có kích thước $[1024, 768]$, tức là 1024 mã mỗi mã mang 768 chiều thông tin tương tự cơ chế biểu diễn từ trong các mô hình bộ biến đổi xử lý ngôn ngữ tự nhiên.

Mã hóa vị trí có nhiệm vụ bổ sung thông tin vị trí không gian cho từng mã. Do bộ biến đổi xử lý tất cả mã song song nên không tự nhận biết được mã nào nằm ở đâu trên ảnh. Vector mã hóa vị trí 768 chiều được cộng trực tiếp vào từng mã nhúng, giúp mô hình xác định được vị trí không gian của từng mảnh ảnh trên ảnh chụp cộng hưởng từ.

Sau hai bước này, chuỗi mã hoàn chỉnh kích thước $[Batch, 1024, 768]$ được đưa vào 4 khối bộ mã hóa của bộ biến đổi liên tiếp. Trong mỗi khối, cơ chế Multi-Head tự chú ý với 12 đầu chú ý học mối quan hệ giữa tất cả các mảnh ảnh, cho phép mô hình:

- mô hình hóa mối quan hệ giữa các vùng đặc trưng nằm cách xa nhau
- Nắm bắt được thông tin ngữ cảnh toàn cục của ảnh não

thay vì chỉ nhìn thấy từng vùng cục bộ nhỏ như Mạng nơ-ron tích chập thuần túy.



Hình 3.4 Quá trình nhúng mảnh và mã hóa vị trí trong mô hình cải tiến

Đầu ra từ bộ mã hóa tại tầng sâu nhất có kích thước: $32 \times 32 \times 512$

Bản đồ đặc trưng này được phân chia thành 1024 mảnh ảnh có kích thước 1×1 , thu được tổng cộng: $32 \times 32 = 1024$

Mỗi mảnh ảnh sau đó được ánh xạ tuyến tính từ không gian đặc trưng 512 chiều sang không gian nhúng 768 chiều

Các vector nhúng được sắp xếp thành chuỗi token một chiều với kích thước:

[Batch, 1024, 768]

Sau đó, vector mã hóa vị trí được cộng vào chuỗi biểu diễn đặc trưng nhằm cung cấp thông tin vị trí không gian của từng mảnh ảnh trên ảnh chụp cộng hưởng từ.


Khối bộ mã hóa

Chuỗi embedding đầu vào truyền qua 4 khối bộ mã hóa của tranformer liên tiếp. Trong mỗi khối, cơ chế tự chú ý đa đầu với 12 đầu chú ý được sử dụng để học mối quan hệ giữa tất cả các mảnh ảnh trong ảnh cộng hưởng từ.

Nhờ khả năng cơ chế tự chú ý toàn cục, mô hình có thể:


- Liên kết các vùng đặc trưng nằm xa nhau
- nắm bắt được thông tin ngữ cảnh toàn cục của ảnh não
- Phát hiện mối liên hệ giữa các vùng bất thường của khối u

Điều này giúp khắc phục hạn chế về trường quan sát cục bộ của Mạng nơ-ron tích chập truyền thống.



Hình 3.5 Kiến trúc một khối mã hóa Transformer trong mô hình cải tiến.

Tái cấu trúc không gian



Hình 3.6 Quá trình tái cấu trúc không gian đầu ra bộ biến đổi thị giác

Sau khi đi qua các khối bộ biến đổi, đầu ra của bộ biến đổi thị giác có kích thước 1024×768

Chuỗi này được tái cấu trúc thành trở lại thành bản đồ đặt trung hai chiều [Batch, 768, 32, 32]

Tiếp theo, một lớp tích chập 3×3 được sử dụng để giảm số lượng kênh đặc trưng từ 768 xuống 512.

Kết quả cuối cùng thu được feature map: $32 \times 32 \times 512$

Bản đồ đặc trưng này đã chứa cả:

- Đặc trưng cục bộ từ Mạng nơ-ron tích chập
- Thông tin ngữ cảnh toàn cục từ bộ biến đổi và sẽ tiếp tục được đưa vào bộ giải mã để tạo ra mặt nạ phân đoạn khối u não.

3.4. Van lọc nhiễu chủ động

Trong kiến trúc mô hình cải tiến, các kết nối tắt từ bộ mã hóa sang bộ giải mã không được truyền trực tiếp như trong U-Net truyền thống mà đi qua một cơ chế chọn lọc đặc trưng gọi là cổng chú ý.

Mục tiêu của cổng chú ý là giảm ảnh hưởng của các đặc trưng không liên quan như nền ảnh, hộp sọ hoặc mô não bình thường, đồng thời tăng cường nhấn mạnh các đặc trưng quan trọng liên quan đến khối u não.

Cổng chú ý thực hiện việc kết hợp hai nguồn tín hiệu:

- Tín hiệu g:

Được gửi từ bộ giải mã, chứa thông tin ngữ nghĩa cấp cao về vùng mà mô hình đang tập trung.

- Tín hiệu x:

Được truyền từ bộ mã hóa, chứa thông tin chi tiết về vị trí không gian và ranh giới đối tượng của ảnh chụp cộng hưởng từ.

Quá trình hoạt động của cổng chú ý

Đầu tiên, hai tín hiệu g và x được đưa qua các lớp tích chập 1×1 nhằm đưa số lượng kênh đặc trưng về cùng kích thước F_{int} .

Sau đó, hai bản đồ đặc trưng được kết hợp thông qua phép cộng và đi qua hàm kích hoạt đơn vị tuyến tính được sửa chữa, tiếp theo là hàm Sigmoid để tạo ra bản đồ chú ý:

Nhờ cơ chế này:

- Các vùng ít liên quan sẽ có trọng số gần 0 và bị suy giảm ảnh hưởng
- Các vùng chứa đặc trưng liên quan đến khối u có trọng số gần 1 được giữ lại

Điều này giúp bộ giải mã tập trung hiệu quả hơn vào vùng tổn thương cần phân đoạn và cải thiện độ chính xác của mô hình trên ảnh chụp cộng hưởng từ.

3.5. Vận hành chi tiết luồng giải mã

Sau khi đi qua khối bộ biến đổi tại nút thắt cổ chai, dữ liệu bắt đầu quá trình phục hồi độ phân giải không gian từ 32×32 về kích thước ảnh gốc 256×256 .

Bộ giải mã gồm nhiều khối giải mã liên tiếp. Mỗi khối bao gồm các bước:


- Nâng cấp độ phân giải (Upsampling) bằng tích chập chuyển vị.
- Lọc đặc trưng bằng công chú ý.
- Ghép đặc trưng.
- Tinh chỉnh đặc trưng bằng hai lớp tích chập liên tiếp.

Khối giải mã thứ nhất

Đầu ra từ bộ biến đổi: $32 \times 32 \times 512$ được đưa qua lớp tích chập chuyển vị để tăng kích thước bản đồ đặc trưng lên $64 \times 64 \times 256$

Bản đồ đặc trưng x_3 từ bộ mã hóa có cùng kích thước không gian được truyền qua công chú ý nhằm loại bỏ các đặc trưng không quan trọng và tạo ra:

$$x_{3_att}$$



Hình 3.7: Cơ chế công chú ý kết hợp kết nối tắt và nâng cấp độ phân giải trong bộ giải mã

Sau đó, bản đồ đã nâng cấp độ phân giải và bản đồ x_{3_att} đã qua công chú ý được nối lại với nhau theo chiều kênh. Cuối cùng, khối dữ liệu ghép này được đưa qua hai lớp tích chập liên tiếp để tạo ra đầu ra của khối giải mã thứ nhất.


Khối giải mã thứ hai

Bản đồ đặc trưng từ khối trước tiếp tục được nâng cấp độ phân giải: $128 \times 128 \times 128$

Bản đồ đặc trưng x_2 từ bộ mã hóa được xử lý qua cổng chú ý để tạo:

$$x_{2_att}$$

Hai bản đồ đặc trưng sau đó được ghép lại và tinh chỉnh qua hai lớp tích chập liên tiếp đầu ra của khối giải mã thứ hai đạt kích thước $128 \times 128 \times 128$.



Hình 3.8 Cơ chế cổng chú ý trong khối giải mã thứ hai


Khối giải mã thứ ba

Bản đồ đặc trưng tiếp tục được tăng kích thước: $256 \times 256 \times 64$

Bản đồ đặc trưng x_1 từ Bộ mã hóa được đưa qua cổng chú ý để tạo:

$$x_{1_att}$$

Sau quá trình nối lại với nhau và tinh chỉnh thông qua hai lớp tích chập liên tiếp, đầu ra cuối cùng của bộ giải mã là: $256 \times 256 \times 64$ đánh dấu việc khôi phục hoàn toàn không gian ảnh gốc.



Hình 3.9 Cơ chế cổng chú ý trong khối giải mã thứ ba

Lớp đầu ra

Bản đồ đặc trưng cuối cùng được đưa qua lớp tích chập 1×1 nhằm ánh xạ từ 64 kênh đặc trưng sang 1 kênh đầu ra [Batch_Size, 1, 256, 256]

Một khối dữ liệu (Tensor) đầu ra này biểu diễn bản đồ xác suất phân đoạn, trong đó:

- Giá trị gần 0 biểu thị vùng nền hoặc mô não bình thường
- Giá trị gần 1 biểu thị vùng khối u não

Sau khi áp dụng ngưỡng phân đoạn, mô hình tạo ra mặt nạ phân đoạn cuối cùng của khối u trên ảnh chụp cộng hưởng từ não.



Hình 3.10 Lớp đầu ra tạo mặt nạ phân đoạn

3.6. Hàm mất mát đa mục tiêu

Hiệu quả của một mô hình phân đoạn không chỉ phụ thuộc vào kiến trúc mạng mà còn phụ thuộc đáng kể vào từ hàm mất mát được sử dụng trong quá trình huấn luyện. Đối với bộ dữ liệu ảnh chụp cộng hưởng từ não, vùng khối u thường chiếm tỷ lệ rất nhỏ so với nền ảnh, dẫn đến hiện tượng mất cân bằng lớp. Nếu sử dụng các hàm mất mát thông thường, mô hình có xu hướng ưu tiên dự đoán lớp nền, làm giảm khả năng phát hiện khối u.

Để khắc phục vấn đề, sử dụng hàm mất mát kết hợp (DiceEntropy) bao gồm hàm mất mát entropy chéo nhị phân và hàm mất mát Dice.

3.6.1. Hàm mất mát Entropy chéo nhị phân (Binary Cross-Entropy Loss)

Hàm mất mát entropy chéo nhị phân đánh giá sai số dự đoán tại từng điểm ảnh bằng cách so sánh xác suất đầu ra của mô hình với nhãn thực tế.

Trong quá trình huấn luyện, đồ án sử dụng tham số trọng số dương: $\text{pos_weight}=15.0$

Tham số này giúp tăng mức phạt đối với các lỗi dự đoán thiếu, tức là trường hợp điểm ảnh thuộc khối u nhưng bị mô hình dự đoán là nền. Nhờ đó,

mô hình được khuyến khích tập trung hơn vào việc phát hiện các vùng khối u nhỏ và khó nhận biết trên ảnh chụp cộng hưởng từ.

3.6.2. Hàm mất mát Dice (Dice Loss)

Hàm mất mát Dice được xây dựng dựa trên chỉ số hệ số tương đồng Dice (Dice Similarity Coefficient - DSC) và tập trung vào mức độ chồng chéo giữa mặt nạ dự đoán và mặt nạ thực tế.

$$Diceloss = 1 - \frac{2TP}{2TP + FP + FN} \quad (3.1)$$

Khác với Entropy chéo nhị phân hàm mất mát chỉ đánh giá từng điểm ảnh riêng lẻ, hàm mất mát Dice tối ưu trực tiếp chất lượng phân đoạn ở mức toàn cục, giúp mô hình:

- Cải thiện độ chính xác của biên khối u
- Tăng mức độ chồng chéo giữa vùng dự đoán và vùng thực tế
- Giảm ảnh hưởng của hiện tượng mất cân bằng lớp

3.6.3. Hàm DiceEntropy chéo nhị phân hàm mất mát

Hai thành phần Entropy chéo nhị phân Hàm mất mát và Hàm mất mát Dice được kết hợp để tạo thành hàm mất mát cuối cùng:

$$DiceBCELoss = BCE + DiceLoss \quad (3.2)$$

Sự kết hợp này cho phép mô hình đồng thời:

- Tối ưu độ chính xác ở mức điểm ảnh
- Tối ưu độ chồng chéo của toàn bộ vùng khối u

Nhờ đó, mô hình cải tiến có khả năng xử lý hiệu quả bài toán phân đoạn khối u não với dữ liệu mất cân bằng cao, đồng thời cải thiện chất lượng mặt nạ phân đoạn so với việc chỉ sử dụng một hàm mất mát đơn lẻ.

CHƯƠNG 4: THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

4.1. Môi trường và thiết lập thực nghiệm

4.1.1. Môi trường phần cứng và phần mềm

Do các mô hình học sâu yêu cầu khả năng tính toán lớn, đặc biệt là các kiến trúc kết hợp Bộ biến đổi, toàn bộ quá trình huấn luyện và đánh giá được thực hiện trên nền tảng Kaggle Notebook với cấu hình như sau:

Phần cứng

CPU: Intel Xeon CPU @ 2.20 GHz

RAM: 30 GB

GPU: NVIDIA Tesla P100 16GB hoặc NVIDIA Tesla T4 16GB

Hệ điều hành: Linux

Phần mềm

- Python 3.10
- PyTorch 2.0
- Torchvision
- NumPy
- Pandas
- Matplotlib
- Scikit-learn

Các thư viện trên được sử dụng để xây dựng mô hình, xử lý dữ liệu, trực quan hóa kết quả và đánh giá hiệu năng của hệ thống.

4.1.2. Thiết lập siêu tham số huấn luyện

Để đảm bảo tính khách quan trong quá trình so sánh, cả hai mô hình U-Net và mô hình đề xuất được huấn luyện với cùng bộ siêu tham số.

Kích thước ảnh đầu vào

Ảnh chụp cộng hưởng từ được chuẩn hóa về kích thước: 256×256

Việc lựa chọn kích thước này giúp cân bằng giữa khả năng giữ lại chi tiết giải phẫu và chi phí tính toán.

Số vòng lặp huấn luyện (Epoch)

Mỗi mô hình được huấn luyện tối đa: 150 epochs

Đồng thời áp dụng cơ chế dừng sớm (Early Stopping) với ngưỡng kiên nhẫn bằng 20 vòng lặp huấn luyện nhằm hạn chế hiện tượng quá khớp.

4.2. Các độ đo đánh giá

Để đánh giá hiệu năng và độ chính xác của kiến trúc đề xuất so với các mô hình mạng nơ-ron truyền thống, nghiên cứu tiến hành đo lường kết quả trên tập dữ liệu kiểm thử dựa trên hai chỉ số phổ biến trong phân đoạn ảnh

Chỉ số Dice: Được sử dụng để đo lường mức độ tương đồng giữa vùng phân đoạn dự đoán và vùng phân đoạn thực tế, phản ánh mức độ chồng lấp tổng thể giữa hai vùng.

Chỉ số IoU: Được sử dụng để đánh giá tỷ lệ giữa phần giao và phần hợp của vùng dự đoán với vùng thực tế, cung cấp thước đo nghiêm ngặt hơn đối với các sai lệch trong quá trình phân đoạn.

4.3. Kết quả đánh giá định lượng

Sau khi huấn luyện, các mô hình được đánh giá trên tập kiểm thử độc lập gồm các ảnh chụp cộng hưởng từ chưa xuất hiện trong quá trình huấn luyện.

Mô hình	Số tham số	Hệ số Dice	Chỉ số IoU	Độ chính xác	Điểm F1	Thời gian dự đoán
U-Net	~17.2M	0.8352	0.8035	0.8563	0.8352	~0.08 giây / 1 ảnh
Mô hình cải tiến	~40.5M	0.8588	0.8252	0.8793	0.8588	~0.12 giây / 1 ảnh

Bảng 4.1 So sánh hiệu năng giữa U-Net và mô hình cải tiến

Kết quả cho thấy mô hình cải tiến đạt hiệu năng tốt hơn trên hầu hết các độ đo đánh giá.

Chỉ số Dice tăng từ: 83.52% lên 85.88%

trong khi IoU tăng từ: 80.35% lên 82.52%

Đặc biệt, Độ chính xác của mô hình cải tiến tốt hơn đáng kể so với U-Net, cho thấy mô hình có khả năng giảm các dự đoán dương tính giả hiệu quả hơn.

4.3.1. Phân tích độ ổn định

Để đánh giá mức độ ổn định của mô hình và xác định liệu sự khác biệt về hiệu năng có mang ý nghĩa thống kê hay không, nghiên cứu tiến hành tính toán độ lệch chuẩn và khoảng tin cậy 95% của chỉ số Dice trên toàn bộ tập kiểm thử.

- U-Net: 0.8352 ± 0.3143 (CI 95%: [0.8133; 0.8570])
- Mô hình cải tiến: 0.8588 ± 0.2831 (CI 95%: [0.8391; 0.8785])

Phân tích độ lệch chuẩn

Giá trị độ lệch chuẩn tương đối cao ở cả hai mô hình phản ánh đặc trưng của tập dữ liệu chụp cộng hưởng từ não. Tập kiểm thử bao gồm cả các lát cắt chứa khối u và các lát cắt không chứa khối u. Đối với những ảnh không chứa vùng tổn thương, chỉ cần mô hình phân loại nhầm một số lượng nhỏ điểm ảnh nền là khối u thì chỉ số Dice có thể suy giảm đáng kể. Do đó, sự biến thiên của chỉ số Dice giữa các ảnh là hiện tượng thường gặp trong bài toán phân đoạn khối u não.

Trong nghiên cứu này, các chỉ số được tính toán trên toàn bộ tập kiểm thử mà không loại bỏ các trường hợp khó hoặc điều chỉnh lại phương pháp đánh giá.

Cách tiếp cận này giúp phản ánh khách quan hiệu năng của mô hình trong điều kiện thực tế.

Nhận xét

Kết quả cho thấy mô hình cải tiến có độ lệch chuẩn thấp hơn so với U-Net, cho thấy hiệu năng của mô hình ổn định hơn trên các trường hợp dữ liệu khác nhau. Bên cạnh đó, khoảng tin cậy 95% của mô hình cải tiến [0.8391,0.8785] nằm ở mức cao hơn so với U-Net [0.8133,0.8570], trong đó cận dưới của mô hình cải tiến (0.8391) cao hơn giá trị chỉ số Dice trung bình của U-Net (0.8352).

Những kết quả này cho thấy mô hình cải tiến đạt hiệu năng phân đoạn tốt hơn và có xu hướng duy trì tính ổn định cao hơn so với U-Net trên tập dữ liệu kiểm thử. Điều này cho thấy mô hình có khả năng thích ứng tốt hơn với sự đa

dạng của dữ liệu, bao gồm các trường hợp có sự khác biệt về kích thước và hình dạng khối u trên ảnh chụp cộng hưởng từ.

4.3.2. Đánh giá tốc độ suy luận

Việc tích hợp khối bộ biến đổi thị giác giúp mô hình cải tiến cải thiện khả năng khai thác ngữ cảnh toàn cục, tuy nhiên cũng làm gia tăng số lượng tham số và chi phí tính toán so với kiến trúc U-Net truyền thống.


Kết quả cho thấy thời gian suy luận của mô hình cải tiến cao hơn đáng kể so với U-Net do phải thực hiện thêm các phép tính trong cơ chế tự chú ý đa đầu của bộ biến đổi. Đây là sự đánh đổi thường gặp giữa độ chính xác và chi phí tính toán trong các mô hình học sâu hiện đại.

Mặc dù tốc độ xử lý thấp hơn, thời gian suy luận trung bình khoảng vài giây cho mỗi ảnh chụp cộng hưởng từ vẫn có thể đáp ứng yêu cầu của các hệ thống hỗ trợ chẩn đoán y khoa, nơi độ chính xác thường được ưu tiên hơn khả năng xử lý thời gian thực. Ngoài ra, khi được triển khai trên các hệ thống sử dụng GPU chuyên dụng, thời gian suy luận có thể được cải thiện đáng kể nhờ khả năng tính toán song song của phần cứng.

Nhận xét: Mô hình cải tiến đạt hiệu năng phân đoạn cao hơn U-Net nhưng phải đánh đổi bằng thời gian suy luận lớn hơn. Tuy nhiên, mức chi phí tính toán tăng thêm, kết quả thực nghiệm cho thấy so với mức cải thiện về hệ số Dice và chỉ số IoU mà mô hình đạt được trên tập dữ liệu Chụp cộng hưởng từ não.

4.3.3. Biểu đồ trực quan hóa quá trình huấn luyện

Để đánh giá trực quan khả năng hội tụ và mức độ ổn định của các mô hình trong quá trình huấn luyện, nghiên cứu sử dụng các biểu đồ minh họa diễn biến của các chỉ số đánh giá theo từng vòng lặp huấn luyện, đồng thời thể hiện sự phân bố kết quả trên tập dữ liệu kiểm thử. Thông qua các biểu đồ này, có thể quan sát rõ hơn xu hướng học tập, khả năng hội tụ và mức độ ổn định của từng mô hình.




Hình 4.1 Biểu đồ tiến trình huấn luyện của mô hình cải tiến

4.3.3.1. Biểu đồ đường cong hàm mất mát (loss curve) của mô hình U-Net

Biểu đồ đường cong hàm mất mát của mô hình U-Net cho thấy quá trình huấn luyện có phần kém ổn định hơn so với mô hình đề xuất. Hàm mất mát trên tập huấn luyện giảm từ ~ 1.42 xuống ~ 0.14 và hội tụ tốt, tuy nhiên hàm mất mát trên tập xác thực (validation loss) dao động mạnh hơn, đặc biệt xuất hiện một đợt tăng đột biến bất thường quanh số vòng huấn luyện 50–60 trước khi ổn định trở lại ở mức ~ 0.40 .

Khoảng cách giữa hàm mất mát trên tập huấn luyện và hàm mất mát trên tập xác thực đạt ~ 0.26 , lớn hơn đáng kể so với mô hình cải tiến, cho thấy mô hình U-Net có xu hướng xuất hiện hiện tượng quá khớp (overfitting) rõ hơn. Nguyên nhân chính là do truyền trực tiếp các đặc trưng từ bộ mã hóa sang bộ giải mã mà không qua bộ lọc, dẫn đến việc các đặc trưng nhiễu như hộp sọ và màng não bị truyền thẳng vào nhánh giải mã, làm giảm khả năng tổng quát hóa của mô hình.




Hình 4.2 Tiến trình huấn luyện U-Net hàm mất mát qua các vòng huấn luyện

4.3.3.2. Biểu đồ đường cong hàm mất mát của mô hình cải tiến


Quan sát biểu đồ đường cong hàm mất mát của mô hình cải tiến, có thể thấy quá trình huấn luyện diễn ra ổn định và hiệu quả. Hàm mất mát trên tập huấn luyện giảm mạnh từ ~ 1.3 xuống còn ~ 0.15 trong 30 vòng huấn luyện đầu, sau đó tiếp tục giảm dần và hội tụ ổn định về ~ 0.15 ở các vòng huấn luyện cuối. hàm mất mát trên tập xác thực cũng có xu hướng giảm tương tự, từ ~ 0.8 xuống còn ~ 0.33 , tuy nhiên vẫn còn dao động nhẹ trong suốt quá trình huấn luyện do tính chất ngẫu nhiên của tập kiểm định.

Khoảng cách giữa hàm mất mát trên tập huấn luyện và hàm mất mát trên tập xác thực duy trì ở mức ~ 0.18 , phản ánh hiện tượng quá khớp ở mức độ nhẹ và chấp nhận được. Điều này cho thấy cơ chế công chú ý đã phát huy hiệu quả trong việc lọc bỏ các đặc trưng nhiễu từ kết nối tắt, giúp mô hình tổng quát hóa tốt hơn trên tập dữ liệu chưa thấy.



Hình 4.3 Tiến trình huấn luyện mô hình cải tiến hàm mất mát qua các vòng huấn luyện

4.3.3.3. Biểu đồ hệ số Dice của U-Net




Hình 4.4 Biểu đồ hệ số Dice của U-Net

Biểu đồ hệ số Dice của mô hình U-Net cho thấy tốc độ hội tụ ban đầu rất nhanh, hệ số Dice trên tập huấn luyện đạt ~0.83 chỉ sau 20 vòng huấn luyện.

Tuy nhiên, Dice trên tập kiểm định dao động mạnh hơn so với mô hình cải tiến, đặc biệt xuất hiện sự giảm đột ngột quanh vòng huấn luyện 50–55 trước khi phục hồi và ổn định ở mức ~ 0.75 vào cuối quá trình huấn luyện.

Khoảng cách hệ số Dice trên tập huấn luyện và Dice trên tập kiểm định đạt ~ 0.16 , lớn hơn mô hình cải tiến, phản ánh xu hướng hiện tượng quá khớp rõ hơn do cơ chế kết nối tắt truyền thông không có bộ lọc đặc trưng, dẫn đến việc các đặc trưng nhiễu được truyền thẳng vào nhánh bộ giải mã làm giảm khả năng tổng quát hóa của mô hình.

4.3.3.4. Biểu đồ hệ số Dice của mô hình cải tiến



Hình 4.5 Biểu đồ hệ số Dice của mô hình cải tiến


Biểu đồ hệ số Dice của mô hình cải tiến cho thấy quá trình huấn luyện diễn ra ổn định và có xu hướng cải thiện liên tục. Hệ số Dice trên tập huấn luyện tăng nhanh từ ~ 0.40 lên ~ 0.80 trong 30 vòng huấn luyện đầu, sau đó tiếp tục tăng dần và hội tụ ổn định ở mức ~ 0.90 vào cuối quá trình huấn luyện. Hệ số Dice trên tập xác thực cũng tăng tương tự, đạt ~ 0.76 ở vòng huấn luyện cuối với mức dao động giảm dần theo thời gian, phản ánh khả năng tổng quát hóa ngày càng được cải thiện.

Khoảng cách giữa hệ số Dice trên tập huấn luyện và chỉ số Dice trên tập xác thực duy trì ở mức ~ 0.14 , cho thấy mô hình chỉ overfitting ở mức độ nhẹ.

Điều này khẳng định hiệu quả của cơ chế công chú ý trong việc lọc bỏ đặc trưng nhiễu, giúp mô hình tập trung học các đặc trưng thực sự liên quan đến khối u não.

4.4. Phân tích trực quan định tính

Việc đánh giá không chỉ dừng ở những chỉ số định lượng đơn thuần. Đồ án đã trích xuất ngẫu nhiên các ca bệnh phức tạp để thực hiện quá trình hiển thị trực quan nhằm kiểm chứng hình dạng thực tế của mặt nạ phân đoạn.



Hình 4.6 Trực quan hóa mặt nạ phân đoạn khối u giữa mô hình U-Net và mô hình cải tiến so với nhãn thực tế 1 (Ground Truth)

Trường hợp này tương ứng với một trường hợp phân đoạn với mức độ khó trung bình, được lấy từ một vị trí lát cắt não bộ chứa các cấu trúc mô thần kinh phức tạp. Khối u có hình thái bất đối xứng, với đường biên tương đối đều đặn, bao phủ tổng cộng 6.647 điểm ảnh.

So sánh hiệu suất hai mô hình:


Cả hai mô hình đều thành công trong việc xác định vị trí không gian của khối u, không xuất hiện hiện tượng dương tính giả lan tỏa trên diện rộng. Tuy nhiên, kết quả phân đoạn cho thấy sự khác biệt đáng chú ý:

Mô hình U-Net dự đoán 6.016 điểm ảnh, ít hơn 631 điểm ảnh so với nhãn chuẩn lý thuyết, đạt chỉ số Dice là 0,8993. Quan sát bản đồ nhiệt xác suất cho thấy vùng kích hoạt của U-Net phân tán không đều, với các vùng cường độ thấp xuất hiện ở các khu vực biên giới, cho thấy mô hình có xu hướng đánh giá thấp khối u, đặc biệt ở các vùng có độ cong cao.

Mô hình cải tiến dự đoán 6.546 điểm ảnh, chỉ thiếu 101 điểm ảnh so với nhãn chuẩn lý thuyết và đạt chỉ số Dice cao hơn là 0,9191. Bản đồ nhiệt cho thấy vùng kích hoạt tập trung đặc và phân bố đều hơn, đặc biệt tại các khu vực biên giới của khối u. Mức độ suy giảm cường độ ở các điểm cầu biên được kiểm soát tốt hơn, cho thấy tính ổn định cao hơn.

Nhận xét tổng thể:

Mô hình cải tiến vượt trội hơn U-Net cả về chỉ số định lượng (Dice cao hơn 2%) và chất lượng định tính (mặt nạ phân đoạn sát hơn với nhãn chuẩn). Việc tích hợp cơ chế Cổng chú ý và đặc trưng từ Bộ biến đổi thị giác đã nâng cao khả năng tập trung vào ranh giới khối u, từ đó cải thiện độ chính xác phân đoạn cho các khối u với hình thái phức tạp.



Hình 4.7 Trực quan hóa mặt nạ phân đoạn khối u giữa mô hình U-Net và mô hình cải tiến so với nhãn thực tế 2

Trường hợp này đặc trưng cho một khối u tương đối nhỏ, được phát hiện tại vị trí thứ ba trong lát cắt não bộ, với kích thước nhân chuẩn lý thuyết là 1.634 điểm ảnh. Khối u có hình thái tương đối đơn giản và phân bố tập trung, cho thấy mức độ phức tạp hình thái thấp hơn so với các trường hợp trước.


So sánh hiệu suất hai mô hình:

Mô hình U-Net dự đoán 1.716 điểm ảnh, vượt quá 82 điểm ảnh so với nhân chuẩn lý thuyết, đạt chỉ số Dice là 0,9552. Mặt nạ phân đoạn nhị phân cho thấy vùng dự đoán có xu hướng mở rộng nhẹ vượt ra ngoài ranh giới khối u. Bản đồ nhiệt xác suất thể hiện vùng kích hoạt tập trung vào lõi khối u, tuy nhiên các cạnh biên giới cho thấy sự lan tỏa cường độ nhẹ, gợi ý khả năng over-segmentation ở các vùng biên.

Mô hình cải tiến dự đoán 1.645 điểm ảnh, chỉ vượt quá 11 điểm ảnh so với nhân chuẩn lý thuyết, đạt hệ số Dice cao hơn là 0,9576. Bản đồ nhiệt cho thấy vùng kích hoạt được kiểm soát chặt hơn, với sự suy giảm cường độ rõ ràng hơn ở khu vực biên giới. Mặt nạ phân đoạn thể hiện ranh giới khối u được mô tả chính xác hơn, sát hơn với nhân gốc.

Nhận xét tổng thể:

Mặc dù cả hai mô hình đều đạt hiệu suất cao, mô hình cải tiến vẫn thể hiện ưu thế vượt trội. Sự khác biệt chỉ số Dice nhỏ được bù đắp bởi độ chính xác của mặt nạ phân đoạn: mô hình cải tiến chỉ over-segment 11 điểm ảnh so với 82 điểm ảnh của U-Net. Kết quả này chứng minh rằng, ngay cả đối với những khối u có hình thái đơn giản, việc tích hợp cơ chế công chú ý và thành phần bộ biến đổi thị giác vẫn giúp mô hình duy trì mức độ kiểm soát ranh giới tốt hơn, góp phần nâng cao tính nhạy cảm của phân đoạn.



Hình 4.8 Trực quan hóa mặt nạ phân đoạn khối u giữa mô hình U-Net và Mô hình cải tiến so với nhãn thực tế 3

Trường hợp này đặc trưng cho một khối u cực nhỏ, kích thước nhãn chuẩn lý thuyết chỉ 539 điểm ảnh, được phát hiện tại vị trí thứ bốn trong tập dữ liệu. Khối u có hình thái tập trung và được bao quanh bởi các cấu trúc não phức tạp, tạo nên một bối cảnh khó khăn cho phân đoạn.

So sánh hiệu suất hai mô hình:

Mô hình mạng U-Net dự đoán 742 điểm ảnh, vượt quá 203 điểm ảnh so với nhãn chuẩn lý thuyết, đạt chỉ số Dice là 0,8290. Bản đồ nhiệt xác suất tiết lộ một vấn đề trầm trọng: vùng kích hoạt không chỉ tập trung vào khối u mà còn lan tỏa rộng rãi sang các vùng mô xung quanh, tạo nên nhiều điểm dương tính giả. Hiện tượng này cho thấy mô hình mạng U-Net thiếu cơ chế để phân biệt khối u với nhiều nền, dẫn đến quá phân đoạn đáng kể.

Mô hình cải tiến dự đoán 556 điểm ảnh, chỉ vượt quá 17 điểm ảnh so với nhãn chuẩn lý thuyết, và đạt chỉ số Dice cao hơn đáng kể là 0,9096. Bản đồ nhiệt cho thấy sự cải thiện chất lượng rõ rệt: vùng kích hoạt tập trung chặt vào khối u, với cường độ giảm dần rõ ràng ở các khu vực biên giới. Hiện tượng dương tính giả được kiểm soát tối ưu, chứng tỏ mô hình có khả năng phân biệt khối u và mô nền tốt hơn.

Nhận xét tổng thể:

Trường hợp này chứng minh rõ nét ưu thế vượt trội của mô hình cải tiến khi đối mặt với khối u cực nhỏ trong bối cảnh không gian nền phức tạp. Sự khác biệt chỉ số Dice lên tới 8,06% là một trong những chênh lệch lớn nhất giữa hai mô hình. Quan trọng hơn, mô hình cải tiến giảm lượng quá phân đoạn từ 203 xuống còn 17 điểm ảnh, tức là giảm 91,6%, phản ánh sự cải thiện tập trung vào độ đặc dị của phân đoạn. Kết quả này là hệ quả trực tiếp của việc tích hợp cơ chế công chú ý, giúp mô hình tập trung vào các vùng chứa khối u, và tính năng tự chú ý từ Bộ biến đổi thị giác, hỗ trợ phân biệt khối u với bối cảnh không gian phức tạp, nâng cao giá trị lâm sàng của kết quả phân đoạn.

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết luận và các đóng góp cốt lõi của đề tài

Sau quá trình nghiên cứu lý thuyết, xây dựng mô hình và thực nghiệm trên bộ dữ liệu LGG MRI, đề tài "Phân đoạn khối u não dựa trên cải tiến U-Net" đã hoàn thành các mục tiêu nghiên cứu đề ra. Đề tài đã đề xuất và xây dựng thành công một kiến trúc phân đoạn ảnh y tế dựa trên U-Net, đồng thời tích hợp các thành phần của Transformer và Cổng chú ý nhằm cải thiện hiệu năng phân đoạn khối u não trên ảnh chụp cộng hưởng từ.

Cải thiện khả năng khai thác thông tin ngữ cảnh toàn cục của U-Net: U-Net truyền thống có ưu thế trong việc trích xuất đặc trưng cục bộ thông qua các lớp tích chập, tuy nhiên khả năng khai thác thông tin ngữ cảnh toàn cục còn hạn chế do phạm vi trường thụ cảm. Đề tài đã tích hợp khối bộ biến đổi thị giác gồm 4 khối và 12 đầu chú ý tại vùng nút thắt cổ chai của mô hình. Kết quả thực nghiệm cho thấy mô hình cải tiến đạt chỉ số Dice 0,8588, cao hơn so với 0,8352 của U-Net.

Nâng cao chất lượng truyền đặc trưng trong các kết nối tắt: Đề tài đã tích hợp cổng chú ý vào các đường kết nối tắt nhằm tăng cường khả năng lựa chọn các đặc trưng có liên quan trước khi truyền sang bộ giải mã. Kết quả thực nghiệm cho thấy mô hình cải tiến đạt hiệu năng phân đoạn cao hơn và có mức độ ổn định tốt hơn so với U-Net trên tập kiểm thử.

Cải tiến hàm mất mát: Để giảm ảnh hưởng của hiện tượng mất cân bằng lớp trong dữ liệu, đề tài sử dụng hàm mất mát DiceBCELoss, kết hợp ưu điểm của Dice Loss và Binary Cross-Entropy Loss. Cách tiếp cận này góp phần nâng cao khả năng nhận diện vùng khối u có kích thước nhỏ và cải thiện hiệu năng phân đoạn của mô hình.

5.2. Các mặt hạn chế còn tồn tại

Mặc dù đạt được kết quả phân đoạn khả quan, do giới hạn về thời gian nghiên cứu và tài nguyên tính toán, mô hình đề xuất vẫn còn một số hạn chế.

Sự đánh đổi về chi phí tính toán: Việc tích hợp Bộ biến đổi thị giác làm số lượng tham số. Điều này dẫn đến thời gian suy luận tăng khoảng 3–4 lần so với U-Net, làm gia tăng yêu cầu về tài nguyên phần cứng khi triển khai trong thực tế.

Giới hạn của mô hình phân đoạn 2D: Mô hình hiện tại thực hiện phân đoạn độc lập trên từng lát cắt ảnh cộng hưởng từ hai chiều. Do đó, mô hình chưa khai thác được mối liên hệ không gian theo chiều sâu giữa các lát cắt liên tiếp, trong khi khối u não là cấu trúc ba chiều.

Hạn chế về tính đa dạng của dữ liệu: Mô hình chỉ được huấn luyện và đánh giá trên bộ dữ liệu LGG MRI gồm 110 bệnh nhân. Vì vậy, khả năng tổng quát hóa của mô hình đối với các loại u não khác hoặc ảnh chụp từ các hệ thống MRI có cấu hình khác nhau vẫn cần được đánh giá thêm.

5.3. Hướng phát triển mở rộng trong tương lai

Để tiếp tục nâng cao hiệu năng và mở rộng khả năng ứng dụng của mô hình trong thực tiễn, một số hướng nghiên cứu có thể được triển khai trong tương lai như sau:

Phát triển mô hình phân đoạn 3D: Chuyển đổi kiến trúc hiện tại từ mô hình phân đoạn hai chiều sang mô hình phân đoạn ba chiều nhằm khai thác mối liên hệ không gian giữa các lát cắt ảnh cộng hưởng từ. Đồng thời, mô hình có thể được huấn luyện và đánh giá trên các bộ dữ liệu quy mô lớn như BraTS, qua đó nâng cao khả năng nhận diện và phân đoạn khối u não.

Tích hợp các phương pháp trí tuệ nhân tạo có khả năng giải thích: Nghiên cứu áp dụng các phương pháp như Grad-CAM để trực quan hóa các vùng đặc trưng mà mô hình sử dụng trong quá trình phân đoạn. Cách tiếp cận này góp phần nâng cao khả năng giải thích của mô hình, hỗ trợ quá trình phân tích kết quả và tăng mức độ tin cậy khi ứng dụng trong lĩnh vực y tế.

DANH MỤC TÀI LIỆU THAM KHẢO

- [1] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," in Medical Image Computing and Computer-Assisted Intervention (MICCAI), Springer, 2015, pp. 234–241.
- [2] J. Chen et al., "TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation," arXiv preprint arXiv:2102.04306, 2021. (Tài liệu gốc về kiến trúc TransUNet).
- [3] M. Buda, A. Saha, and M. A. Mazurowski, "Association of genomic subtypes of lower-grade gliomas with shape features automatically extracted by a deep learning algorithm," Computers in Biology and Medicine, vol. 109, pp. 418-425, 2019.
- [4] Tue-Thu Van-Dinh, Hoang-Duy Tran, Quang-Vinh Dinh, Phuc-Thinh Nguyen, "Segmentation với U-Net," AI Viet Nam Blog, 2024. [Trực tuyến]. Truy cập tại: <https://aivietnam.edu.vn/blog/intro-to-unet#u-net>. Truy cập ngày: 25/04/2026